École Nationale Supérieure d'Ingénieurs de Tunis (ENSIT)
GMAM 3 — Module « Sûreté de fonctionnement et maintenance »
Projet pratique en binôme

Estimation des indices FMDS et maintenance prédictive d'une flotte de turboréacteurs

Fiabilité, maintenabilité, disponibilité, détection de l'état de santé et estimation de la durée de vie résiduelle sur le jeu NASA C-MAPSS FD001

Rapport scientifique — Version 1

Eya DHRIF et **Salma MOUEDDEB**
Encadrant : M. Fayçal Ben Hmida

Résumé

Ce rapport présente une étude de sûreté de fonctionnement et de maintenance prédictive menée sur le jeu de données public NASA C-MAPSS, sous-ensemble FD001, qui simule la dégradation jusqu'à la défaillance de turboréacteurs d'avion [1, 2]. L'étude suit deux axes complémentaires.

Le premier axe estime les indices FMDS de la flotte. Les 100 moteurs d'entraînement fournissent des durées de défaillance observées et les 100 moteurs de test des durées censurées à droite. L'estimateur de Kaplan-Meier, l'estimateur de Nelson-Aalen et plusieurs lois paramétriques sont comparés. La loi de Weibull à trois paramètres est retenue (β = 1,83, η = 91,3 cycles, γ = 125,2 cycles, test de Kolmogorov-Smirnov accepté avec p = 0,32). Elle donne un MTTF de 206,3 cycles et une durée B10 de 151,9 cycles. À partir de temps de réparation simulés, hypothèse rendue nécessaire par l'absence de données de réparation, la disponibilité intrinsèque vaut 95,98 % et une politique de remplacement préventif à l'âge 131 cycles réduit le coût par cycle de 68 %.

Le second axe construit une chaîne de maintenance prédictive : sélection de 12 capteurs pronostiques, indicateur de santé, détection de l'état critique (AUC de test 0,991) et estimation de la durée de vie résiduelle (RUL) par deux modèles. Un modèle de dégradation bayésien interprétable atteint un RMSE de 24,47 cycles ; un réseau LSTM atteint 15,35 cycles. Le modèle de dégradation fournit un intervalle de prédiction, mais celui-ci est trop étroit : l'intervalle nominal P10–P90 ne couvre le RUL réel que dans 54 % des cas. Les résultats sont servis par une API et un tableau de bord web, et chaque chiffre de ce rapport est produit par le code et vérifié par une suite de tests automatiques.

Mots-clés : fiabilité, censure à droite, Kaplan-Meier, Weibull à trois paramètres, disponibilité, remplacement préventif, indicateur de santé, durée de vie résiduelle, modèle bayésien, LSTM, C-MAPSS.

Table des matières

Résumé
Table des matières
Liste des figures
Liste des tableaux

1 Introduction
- **1.1** Contexte industriel
- **1.2** Problématique et objectifs
- **1.3** Contributions
- **1.4** Organisation du rapport

2 État de l'art ciblé
- **2.1** Les indices FMDS
- **2.2** Estimation non paramétrique et paramétrique de la fiabilité
- **2.3** Maintenance préventive et maintenance prédictive
- **2.4** Indicateurs de santé
- **2.5** Approches d'estimation de la durée de vie résiduelle
- **2.6** Travaux sur C-MAPSS

3 Données
- **3.1** Origine et protocole de simulation

3.2 Structure et tailles exactes
3.3 Censure à droite
3.4 Capteurs constants et analyse exploratoire

4 Méthodologie
4.1 Fiabilité (FMDS-01, Eya)
4.2 Maintenabilité et disponibilité (FMDS-02, Salma)
4.3 Sélection des capteurs et indicateur de santé (PDM-01, Salma)
4.4 Classification de l'état de santé (PDM-02, Eya)
4.5 Estimation du RUL par modèle de dégradation bayésien (RUL-01, Eya)
4.6 Estimation du RUL par réseau LSTM (RUL-02, Salma)

5 Architecture et workflow du système
5.1 Pipeline de calcul
5.2 API et endpoints
5.3 Tableau de bord
5.4 Reproductibilité et qualité

6 Protocole expérimental et métriques
6.1 Découpages des données et validation
6.2 Métriques

7 Résultats
7.1 Fiabilité
7.2 Maintenabilité, disponibilité et politique préventive
7.3 Indicateur de santé et détection de l'état critique
7.4 Durée de vie résiduelle
7.5 Comparaison des méthodes

8 Discussion
8.1 Interprétation industrielle
8.2 Limites actuelles

9 Perspectives
9.1 Modèles de dégradation probabilistes plus avancés
9.2 Amélioration de l'estimation du RUL et de la quantification des incertitudes
9.3 Étude approfondie des indicateurs B10 et B50
9.4 Intégration de covariables externes
9.5 Explicabilité des modèles d'apprentissage
9.6 Stratégies de pondération
9.7 Analyses de sensibilité et de robustesse
9.8 Benchmarks élargis, apprentissage profond et Transformers
9.9 Passage à des données industrielles réelles
9.10 Modèles hybrides et apprentissage informé par la physique
9.11 Optimisation avancée de la planification de la maintenance
9.12 Jumeau numérique
9.13 Étude économique industrielle complète

9.14 Déploiement et validation en environnement industriel

10 Conclusion

Bibliographie

Annexes

Annexe A — Hypothèses et paramètres

Annexe B — Structure du dépôt

Annexe C — Guide de lancement

Annexe D — Répartition du travail

Liste des figures

Figure 1 – Distribution des durées de vie des moteurs d'entraînement (gauche) et des durées observées des moteurs de test, censurées à droite (droite).

Figure 2 – Signaux bruts de capteurs retenus pour le premier moteur d'entraînement et leur moyenne glissante : la dérive progressive vers la défaillance est visible malgré le bruit.

Figure 3 – Page « Vue d'ensemble » : indicateurs clés, distribution des durées de vie, état de la flotte en service et priorités d'intervention.

Figure 4 – Page « Fiabilité & FMDS » : fonction de fiabilité, paramètres estimés, adéquation des lois, maintenabilité, disponibilité et politique préventive.

Figure 5 – Page « Monitoring santé » : sélection des capteurs, indicateur de santé, performances de la classification et suivi d'un moteur.

Figure 6 – Page « Durée de vie résiduelle » : métriques des deux modèles, prédictions pour la flotte, calibration et analyse moteur par moteur.

Figure 7 – Fonction de fiabilité : estimateur de Kaplan-Meier avec son intervalle de confiance et les censures, comparé à la loi de Weibull 3P retenue et à la loi de Weibull 2P (MV) rejetée.

Figure 8 – Taux de défaillance : estimation non paramétrique de Nelson-Aalen lissée par noyau et taux de la loi de Weibull 3P.

Figure 9 – Diagramme de Weibull (rangs médians de Bernard) et droite des moindres carrés : la courbure révèle un paramètre de position non nul.

Figure 10 – Densité de défaillance et fonction de répartition de la loi de Weibull 3P, avec les durées B10 et B50.

Figure 11 – Fiabilité conditionnelle : probabilité qu'un moteur ayant atteint l'âge t fonctionne encore pendant l'horizon suivant (ligne pointillée : niveau 0,9).

Figure 12 – Temps de réparation simulés (gauche) et fonction de maintenabilité de la loi log-normale estimée, avec le MTTR et la durée t90 (droite).

Figure 13 – Disponibilité instantanée A(t) selon le modèle markovien à deux états et sa limite asymptotique.

Figure 14 – Coût moyen par cycle de la politique de remplacement à âge fixe en fonction de l'âge T, comparé au coût de la maintenance corrective seule.

Figure 15 – Tendance des capteurs non constants : corrélation moyenne avec le numéro de cycle ; les capteurs retenus dépassent le seuil en valeur absolue.

Figure 16 – Indicateur de santé lissé de dix moteurs d'entraînement et seuil de défaillance.

Figure 17 – Poids des capteurs standardisés dans l'indicateur de santé.

Figure 18 – Courbes ROC des deux classifieurs sur le jeu de test.

Figure 19 – Matrice de confusion du gradient boosting sur le jeu de test, au seuil de décision par défaut.

Figure 20 – RUL prédit en fonction du RUL réel pour les deux modèles ; la diagonale correspond à une prédiction parfaite.

Figure 21 – Distribution des erreurs de prédiction ; une erreur positive est une prédiction tardive.

Figure 22 – Prédictions des deux modèles pour les moteurs de test triés par RUL réel, avec l'intervalle P10–P90 du modèle de dégradation.

Figure 23 – Calibration des intervalles du modèle de dégradation : couverture observée en fonction du niveau nominal.

Figure 24 – Courbes d'apprentissage du LSTM : RMSE d'entraînement et de validation par époque.

Figure 25 – Moteur de test pris en exemple : RUL prédit à chaque cycle par les deux modèles (gauche) et projection de l'indicateur de santé jusqu'au seuil de défaillance (droite).

Liste des tableaux

Tableau 1 – Tailles exactes et statistiques du jeu C-MAPSS FD001

Tableau 2 – Variables de FD001 (statistiques sur le jeu d'entraînement)

Tableau 3 – Modèles de fiabilité estimés sur les 100 durées de défaillance

Tableau 4 – Adéquation des lois candidates (MV sur les durées complètes)

Tableau 5 – Indicateurs de fiabilité

Tableau 6 – Maintenabilité, disponibilité et remplacement préventif (temps de réparation simulés)

Tableau 7 – Classification normal / critique (RUL ≤ 30 cycles)

Tableau 8 – Performances des modèles de RUL sur les 100 moteurs de test

Tableau 9 – Calibration des intervalles du modèle de dégradation

Tableau 10 – Biais du modèle de dégradation selon le RUL réel

Tableau 11 – Hypothèses et paramètres des méthodes

1 Introduction

1.1 Contexte industriel

La maintenance des turboréacteurs représente une part importante du coût d'exploitation d'une flotte aérienne. Une défaillance en service entraîne l'immobilisation de l'appareil, des réparations plus lourdes, des pénalités opérationnelles et des risques pour la sécurité. À l'inverse, un remplacement trop précoce gaspille une partie de la vie utile des composants. La norme NF EN 13306 [3] distingue trois familles de stratégies : la maintenance **corrective**, réalisée après la défaillance ; la maintenance **préventive systématique**, réalisée à intervalles fixes ; et la maintenance **conditionnelle et prévisionnelle**, déclenchée par l'état mesuré du bien et par la prévision de son évolution [4].

Choisir entre ces stratégies demande deux types de connaissances. Il faut d'abord connaître le comportement statistique de la flotte : la loi des durées de vie, le taux de défaillance, la maintenabilité et la disponibilité, c'est-à-dire les indices **FMDS** (fiabilité, maintenabilité, disponibilité, sécurité) [5]. Il faut ensuite savoir estimer, pour chaque moteur en service, son état de santé et sa **durée de vie résiduelle** (en anglais *remaining useful life*, RUL), à partir des mesures de ses capteurs [6, 7].

1.2 Problématique et objectifs

Ce projet s'appuie sur le jeu de données NASA C-MAPSS, sous-ensemble FD001 [1, 2]. Il contient les séries de capteurs de turboréacteurs simulés : des moteurs suivis jusqu'à la défaillance (entraînement) et des moteurs dont la série s'arrête avant la défaillance (test). La problématique est la suivante : *à partir de ces seules données, comment quantifier la fiabilité de la flotte, en déduire une politique de maintenance préventive, puis aller au-delà avec une maintenance prédictive moteur par moteur ?*

Les objectifs sont :

- estimer les indices FMDS de la flotte en tenant compte de la censure des moteurs encore en service (tickets FMDS-01 et FMDS-02) ;
- construire un indicateur de santé à partir des capteurs et détecter les moteurs proches de la défaillance (PDM-01 et PDM-02) ;
- estimer la durée de vie résiduelle par deux approches de natures différentes, un modèle de dégradation probabiliste et un réseau de neurones récurrent, puis les comparer (RUL-01 à RUL-03) ;
- mettre ces résultats à disposition dans une API et un tableau de bord web (WEB-01 et WEB-02).

1.3 Contributions

Les travaux réalisés dans cette Version 1 sont les suivants :

1. une analyse de fiabilité complète avec censure à droite : estimateurs non paramétriques, quatre lois candidates, tests d'adéquation, choix argumenté d'une loi de Weibull à trois paramètres et indicateurs dérivés (MTTF, B1, B10, B50) ;
2. une étude de maintenabilité et de disponibilité fondée sur une hypothèse de temps de réparation explicitement signalée, et l'optimisation d'une politique de remplacement préventif à âge fixe ;
3. une chaîne de maintenance prédictive : sélection des capteurs, indicateur de santé, classification de l'état et deux modèles de RUL, dont un modèle bayésien qui fournit une distribution de la durée de vie résiduelle ;

4. un diagnostic honnête des limites, en particulier la calibration insuffisante des intervalles du modèle de dégradation ;
5. un système logiciel reproductible (pipeline, API, tableau de bord), dont chaque résultat est vérifié par une suite de tests automatiques.

1.4 Organisation du rapport

Le chapitre 2 présente un état de l'art ciblé. Le chapitre 3 décrit les données. Le chapitre 4 détaille les méthodes, leurs fondements mathématiques et leurs hypothèses. Le chapitre 5 décrit l'architecture logicielle et le chapitre 6 le protocole expérimental. Les résultats sont présentés au chapitre 7 et discutés au chapitre 8. Le chapitre 9 expose les perspectives, avant la conclusion (chapitre 10).

2 État de l'art ciblé

2.1 Les indices FMDS

La sûreté de fonctionnement d'un bien se décrit par quatre grandeurs [5, 3]. La **fiabilité** $R(t)$ est la probabilité que le bien accomplisse sa fonction sur l'intervalle $[0, t]$. La **maintenabilité** $M(t)$ est la probabilité qu'une réparation soit achevée avant la durée t. La **disponibilité** $A(t)$ est la probabilité que le bien soit en état de fonctionner à l'instant t. La **sécurité** concerne l'absence d'événements critiques pour les personnes et l'environnement ; elle n'est pas quantifiée dans ce projet, faute de données sur la gravité des défaillances. Les indicateurs usuels en découlent : MTTF (durée moyenne de fonctionnement avant défaillance), MTTR (durée moyenne de réparation), MTBF, MUT et MDT, ainsi que les durées B_p, âges auxquels une proportion p de la population a défailli.

2.2 Estimation non paramétrique et paramétrique de la fiabilité

Lorsque certaines unités n'ont pas encore défailli à la fin de l'observation, leurs durées sont **censurées à droite** : on sait seulement qu'elles dépassent la durée observée. Les ignorer biaiserait l'estimation vers des durées trop courtes. L'estimateur de Kaplan-Meier [8] traite la censure en ne retirant une unité censurée que de l'effectif à risque. Sa variance s'estime par la formule de Greenwood [9]. L'estimateur de Nelson-Aalen [10, 11] estime le taux de défaillance cumulé ; son lissage par noyau donne une estimation non paramétrique du taux de défaillance $\lambda(t)$.

L'approche paramétrique suppose une loi. La loi de Weibull [12] est la référence en fiabilité mécanique : son paramètre de forme β distingue les défaillances de jeunesse ($\beta < 1$), aléatoires ($\beta = 1$) et d'usure ($\beta > 1$). Ses paramètres s'estiment soit par moindres carrés sur le diagramme de Weibull, avec les rangs médians de Bernard [13], soit par maximum de vraisemblance. L'adéquation se juge par le test de Kolmogorov-Smirnov [14] et les lois candidates se comparent par le critère d'information d'Akaike (AIC) [15].

2.3 Maintenance préventive et maintenance prédictive

La politique de **remplacement à âge fixe** de Barlow et Proschan [16] remplace préventivement un bien à l'âge T s'il n'a pas défailli avant. L'âge optimal minimise le coût moyen par unité de temps ; il n'existe un optimum fini que si le taux de défaillance est croissant. Cette politique traite tous les moteurs de la même façon. La maintenance **prédictive**, ou PHM (*prognostics and health management*), décide au contraire moteur par moteur à partir de son état mesuré [4, 6].

2.4 Indicateurs de santé

Un indicateur de santé (*health indicator*, HI) résume l'état d'un système en une grandeur scalaire, idéalement monotone au cours de la dégradation. Coble et Hines [17] proposent de sélectionner les capteurs selon leur monotonie, leur tendance et leur pronosticabilité. Wang et al. [18] construisent un HI par régression linéaire des capteurs vers une cible qui vaut un en début de vie et zéro à la défaillance : c'est l'approche suivie dans ce projet.

2.5 Approches d'estimation de la durée de vie résiduelle

Les méthodes d'estimation du RUL se répartissent en deux familles [7, 6].

Les **modèles de dégradation statistiques** décrivent l'évolution d'un indicateur jusqu'à un seuil de défaillance. Gebraeel et al. [19] proposent un modèle à coefficients aléatoires dont l'a priori est appris sur une flotte et mis à jour de façon bayésienne avec les mesures de chaque unité, ce qui donne une distribution du RUL. Les processus de diffusion, comme le processus de Wiener, en sont une généralisation [20].

Les **méthodes d'apprentissage automatique** apprennent directement la relation entre les mesures et le RUL. Les réseaux récurrents [21], en particulier les LSTM [22, 23], et les réseaux convolutifs [24, 25] sont devenus la référence sur C-MAPSS. Ils sont plus précis, mais moins interprétables et ne fournissent pas nativement d'incertitude.

2.6 Travaux sur C-MAPSS

Le jeu C-MAPSS a été produit avec le simulateur de turboréacteur de la NASA [2] et compte quatre sous-ensembles, de FD001 (une condition opératoire, un mode de défaillance) à FD004 (six conditions, deux modes). Ramasso et Saxena [26] recensent et comparent les nombreuses méthodes publiées. Deux conventions y sont devenues usuelles et sont reprises ici : la cible de RUL plafonnée pendant la phase saine [21] et le score asymétrique du challenge PHM, qui pénalise davantage les prédictions tardives [2].

3 Données

3.1 Origine et protocole de simulation

Les données proviennent du simulateur C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) de la NASA [2]. Chaque moteur démarre avec un niveau d'usure initial et une dispersion de fabrication inconnus, considérés comme normaux. Au cours des cycles de vol, une dégradation est injectée dans le compresseur haute pression (HPC) jusqu'à la défaillance, définie par le franchissement d'une marge de fonctionnement. Les mesures sont bruitées. Le sous-ensemble FD001 retenu ici est le plus simple : **une seule condition opératoire** (niveau de la mer) et **un seul mode de défaillance** (dégradation du HPC) [1].

3.2 Structure et tailles exactes

Chaque ligne des fichiers correspond à un cycle de vol d'un moteur et contient le numéro du moteur, le numéro de cycle, 3 réglages opérationnels et 21 capteurs (températures, pressions, vitesses de rotation, débits). Trois fichiers sont utilisés :

- `train_FD001.txt` : 100 moteurs suivis jusqu'à la défaillance, soit 20 631 lignes ;
- `test_FD001.txt` : 100 autres moteurs, dont la série s'arrête à un instant inconnu avant la défaillance, soit 13 096 lignes ;
- `RUL_FD001.txt` : la durée de vie résiduelle réelle de chaque moteur de test à son dernier cycle observé.

Le tableau 1 résume les tailles et les statistiques principales. Les durées de vie d'entraînement vont de 128 à 362 cycles, avec une moyenne de 206,3 cycles. Les séries de test sont plus courtes, de 31 à 303 cycles (moyenne 131,0), et leur RUL réel va de 7 à 145 cycles (moyenne 75,5).

Tableau 1 – Tailles exactes et statistiques du jeu C-MAPSS FD001

Élément	Valeur
Lignes d'entraînement / de test	20 631 / 13 096
Moteurs d'entraînement / de test	100 / 100
Variables	21 capteurs + 3 réglages opérationnels
Durée de vie (entraînement) : min. – max., moyenne	128 – 362 cycles, 206,3
Longueur des séries de test : min. – max., moyenne	31 – 303 cycles, 131,0
RUL réel de test : min. – max., moyenne	7 – 145 cycles, 75,5
Unités pour la fiabilité	200 (100 défaillances, 100 censures à droite)

La figure 1 montre la distribution des durées. Un fait est essentiel pour la suite : **aucun moteur ne défaille avant 128 cycles**. Cette période sans défaillance orientera le choix d'une loi à seuil au section 4.1.

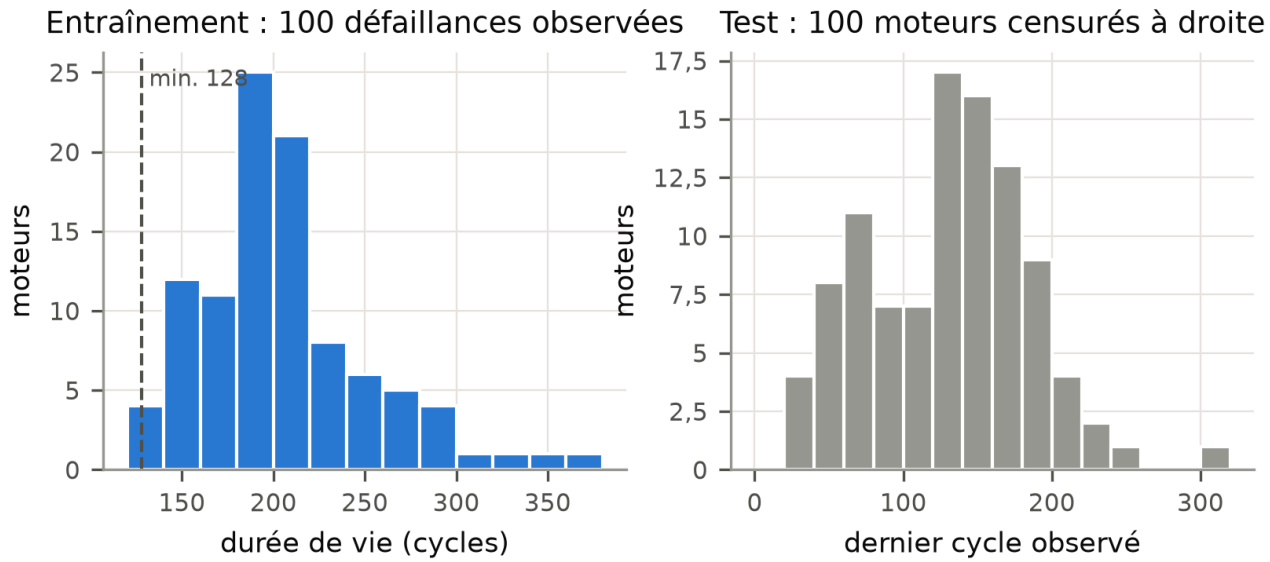


Figure 1 – Distribution des durées de vie des moteurs d'entraînement (gauche) et des durées observées des moteurs de test, censurées à droite (droite).

3.3 Censure à droite

Pour l'analyse de fiabilité, les 200 moteurs forment une seule population. Les 100 moteurs d'entraînement fournissent des **durées de défaillance observées** (statut $\delta = 1$). Les 100 moteurs de test étaient encore en fonctionnement à leur dernier cycle observé : leur durée de vie est seulement connue pour être supérieure à ce cycle. Ce sont des **censures à droite** (statut $\delta = 0$). Le RUL réel des moteurs de test n'est pas utilisé dans l'analyse de fiabilité : il sert uniquement à évaluer les modèles de RUL, ce qui évite toute fuite d'information entre les deux parties de l'étude.

3.4 Capteurs constants et analyse exploratoire

Le tableau 2 donne les statistiques des 21 capteurs et des réglages sur le jeu d'entraînement. Avec une seule condition opératoire, plusieurs capteurs ne varient pas ou presque : 7 capteurs présentent moins de 10 valeurs distinctes sur tout le jeu et sont écartés (s1, s5, s6, s10, s16, s18, s19). Les réglages opérationnels ne portent pas d'information de dégradation. Les autres capteurs dérivent progressivement au cours de la vie du moteur, comme le montre la figure 2 pour 6 d'entre eux : certains croissent (températures, pression statique en sortie du HPC), d'autres décroissent (pression en sortie du HPC, débits de refroidissement). Le bruit de mesure est important à l'échelle d'un cycle, d'où l'intérêt des moyennes glissantes.

Tableau 2 – Variables de FD001 (statistiques sur le jeu d'entraînement)

Variable	Description	Moyenne	Écart-type	Valeurs distinctes	Statut
set1	Réglage opérationnel 1	0,000	0,002	158	réglage
set2	Réglage opérationnel 2	0,000	0,000	13	réglage
set3	Réglage opérationnel 3	100,000	0,000	1	réglage
s1	T2 — Température entrée fan (°R)	518,670	0,000	1	constant, écarté
s2	T24 — Température sortie LPC (°R)	642,681	0,500	310	retenu
s3	T30 — Température sortie HPC (°R)	1 590,523	6,131	3 012	retenu
s4	T50 — Température sortie LPT (°R)	1 408,934	9,001	4 051	retenu
s5	P2 — Pression entrée fan (psia)	14,620	0,000	1	constant, écarté
s6	P15 — Pression bypass (psia)	21,610	0,001	2	constant, écarté
s7	P30 — Pression sortie HPC (psia)	553,368	0,885	513	retenu
s8	Nf — Vitesse physique fan (rpm)	2 388,097	0,071	53	retenu
s9	Nc — Vitesse physique core (rpm)	9 065,243	22,083	6 403	non retenu
s10	epr — Rapport de pression moteur	1,300	0,000	1	constant, écarté
s11	Ps30 — Pression statique sortie HPC (psia)	47,541	0,267	159	retenu
s12	phi — Débit carburant / Ps30	521,414	0,738	427	retenu
s13	NRf — Vitesse corrigée fan (rpm)	2 388,096	0,072	56	retenu
s14	NRc — Vitesse corrigée core (rpm)	8 143,753	19,076	6 078	non retenu
s15	BPR — Taux de dilution	8,442	0,038	1 918	retenu
s16	farB — Rapport carburant/air brûleur	0,030	0,000	1	constant, écarté
s17	htBleed — Enthalpie de prélèvement	393,211	1,549	13	retenu
s18	Nf_dmd — Vitesse fan demandée	2 388,000	0,000	1	constant, écarté
s19	PCNfR_dmd — Vitesse fan corrigée demandée	100,000	0,000	1	constant, écarté
s20	W31 — Débit air refroidissement HPT	38,816	0,181	120	retenu
s21	W32 — Débit air refroidissement LPT	23,290	0,108	4 745	retenu

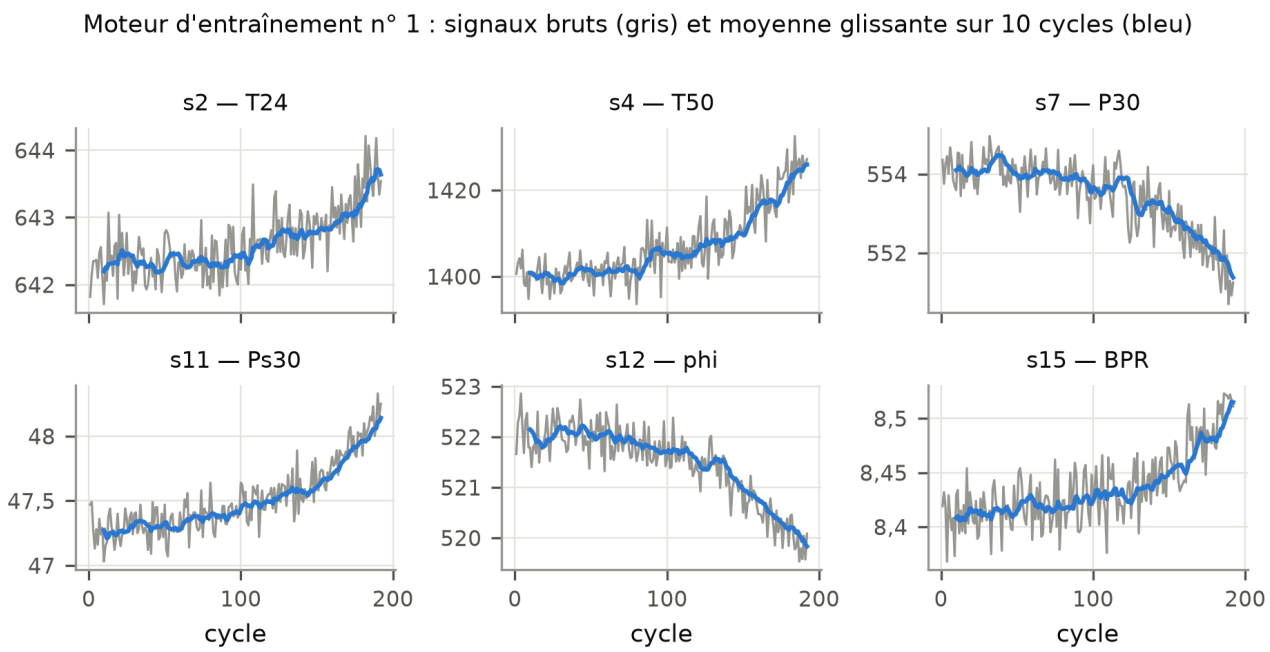


Figure 2 – Signaux bruts de capteurs retenus pour le premier moteur d'entraînement et leur moyenne glissante : la dérive progressive vers la défaillance est visible malgré le bruit.

4 Méthodologie

Ce chapitre présente, pour chaque méthode, ses fondements mathématiques, ses hypothèses et le choix de ses paramètres. Les valeurs numériques des paramètres sont lues directement dans le code ; elles sont regroupées au tableau 11 (annexe). Chaque section indique le ticket du plan de sprints et la personne responsable.

4.1 Fiabilité (FMDS-01, Eya)

4.1.1 Estimateur de Kaplan-Meier

Soient $t_1 < t_2 < \dots$ les instants distincts de défaillance, d_i le nombre de défaillances en t_i et n_i le nombre d'unités encore à risque juste avant t_i (ni défaillies, ni censurées). L'estimateur de Kaplan-Meier [8] est

$$\hat{R}(t) = \prod_{t_i \le t} \left(1 - \frac{d_i}{n_i}\right). \tag{1}$$

Une unité censurée en c contribue à l'effectif à risque jusqu'à c, puis en sort sans être comptée comme défaillance. La variance est estimée par la formule de Greenwood [9] :

$$\widehat{\mathrm{Var}}\big[\hat{R}(t)\big] = \hat{R}(t)^2 \sum_{t_i \le t} \frac{d_i}{n_i (n_i - d_i)}. \tag{2}$$

L'intervalle de confiance à $95\,\%$ est construit sur la transformation $\log(-\log \hat{R})$, qui garantit des bornes dans $[0, 1]$. La durée médiane de survie est le plus petit t tel que $\hat{R}(t) \le 0{,}5$, et l'aire sous la courbe de Kaplan-Meier donne une estimation non paramétrique de la durée moyenne.

Hypothèse : la censure est non informative, c'est-à-dire que l'arrêt de l'observation d'un moteur de test ne dépend pas de son état. Dans C-MAPSS, l'instant de troncature des séries de test est tiré indépendamment de la dégradation [2], ce qui justifie cette hypothèse.

4.1.2 Estimateur de Nelson-Aalen et taux de défaillance

Le taux de défaillance cumulé est estimé par [10, 11]

$$\hat{H}(t) = \sum_{t_i \le t} \frac{d_i}{n_i}, \qquad \hat{R}_{NA}(t) = e^{-\hat{H}(t)}. \tag{3}$$

Le taux de défaillance instantané $\lambda(t)$ est obtenu en lissant les incréments d_i/n_i par un noyau d'Epanechnikov de largeur $b = 15$ cycles. Ce lissage est non paramétrique : il permet de vérifier la forme de $\lambda(t)$ sans supposer de loi.

4.1.3 Lois paramétriques et estimation

La loi de Weibull à trois paramètres [12] a pour fonction de fiabilité et taux de défaillance

$$R(t) = \begin{cases} 1 & t \le \gamma \\ \exp\left[-\left(\dfrac{t-\gamma}{\eta}\right)^{\beta}\right] & t > \gamma \end{cases}, \qquad \lambda(t) = \frac{\beta}{\eta}\left(\frac{t-\gamma}{\eta}\right)^{\beta-1} \ \text{pour } t > \gamma, \tag{4}$$

avec β le paramètre de forme, η le paramètre d'échelle et γ le paramètre de position, ou durée sans défaillance garantie. La loi à deux paramètres correspond à $\gamma = 0$.

Moindres carrés ordinaires (MCO), la méthode graphique du cours [5]. Les n durées de défaillance triées reçoivent la fonction de répartition empirique de Bernard [13], et la loi de Weibull 2P se linéarise :

$$\hat{F}_i = \frac{i - 0{,}3}{n + 0{,}4}, \qquad \ln\!\big(-\ln(1-\hat{F}_i)\big) = \beta \ln t_i - \beta \ln \eta. \tag{5}$$

La droite de régression donne β (pente) et η, et le coefficient R^2 mesure la linéarité du diagramme. Une courbure du diagramme signale un paramètre de position non nul.

Maximum de vraisemblance (MV). Pour des durées t_i de statut δ_i ($\delta_i = 1$: défaillance, $\delta_i = 0$: censure), la log-vraisemblance est

$$\ell(\theta) = \sum_{i} \Big[\delta_i \ln f(t_i;\theta) + (1-\delta_i)\ln R(t_i;\theta)\Big]. \tag{6}$$

Deux estimations sont réalisées. La première, avec censure, porte sur les 200 unités et la loi de Weibull 2P (bibliothèque lifelines [27]) ; elle donne un intervalle de confiance sur β. La seconde porte sur les 100 **durées de défaillance complètes** ($\delta_i = 1$) et sert à comparer quatre lois candidates : exponentielle, Weibull 2P, log-normale et Weibull 3P (bibliothèque SciPy). **La loi retenue, Weibull 3P, est donc ajustée sur les seules défaillances observées** : ce choix et ses conséquences sont discutés au section 8.2.

4.1.4 Validation et choix du modèle

L'adéquation de chaque loi est testée par le test de Kolmogorov-Smirnov [14], de statistique $D = \sup_t |F_n(t) - F(t)|$, au seuil $\alpha = 5\,\%$. Les lois sont comparées par le critère d'Akaike [15], $\mathrm{AIC} = 2k - 2\ell$, où k est le nombre de paramètres : il pénalise la complexité. Une différence d'AIC inférieure à deux unités indique deux modèles équivalents.

4.1.5 Indicateurs dérivés

Pour la loi de Weibull 3P, la durée moyenne de fonctionnement avant défaillance et la durée B_p (âge auquel une proportion p a défailli) valent

$$\mathrm{MTTF} = \gamma + \eta\,\Gamma\!\left(1 + \frac{1}{\beta}\right), \qquad B_p = \gamma + \eta\big(-\ln(1-p)\big)^{1/\beta}. \tag{7}$$

Le rapport utilise B_1, B_{10} et B_{50} (durée médiane). La **fiabilité conditionnelle** donne la probabilité qu'un moteur ayant atteint l'âge t fonctionne encore Δ cycles plus tard, avec $\Delta = 25$ cycles :

$$R(t + \Delta \mid t) = \frac{R(t+\Delta)}{R(t)}. \tag{8}$$

4.2 Maintenabilité et disponibilité (FMDS-02, Salma)

4.2.1 Hypothèse sur les temps de réparation

> **Hypothèse forte.** C-MAPSS ne contient aucun temps de réparation. Pour illustrer la démarche du cours, des temps de réparation sont **simulés** : un temps par défaillance observée, tiré selon une loi log-normale de médiane 16 h et d'écart-type logarithmique 0,6, avec une graine fixe (42). La conversion entre unités suppose qu'un cycle correspond à un vol d'environ 2 h. Les résultats de cette section illustrent la méthode ; ils ne décrivent pas une flotte réelle.

La loi log-normale est le modèle usuel des durées de réparation, car celles-ci sont positives et asymétriques. Ses paramètres sont ré-estimés par maximum de vraisemblance sur l'échantillon simulé, et l'ajustement est vérifié par le test de Kolmogorov-Smirnov. La maintenabilité, le MTTR et la durée t_{90} (90 % des réparations terminées) valent

$$M(t) = \Phi\!\left(\frac{\ln t - \mu}{\sigma}\right), \qquad \mathrm{MTTR} = e^{\mu + \sigma^2/2}, \qquad t_{90} = e^{\mu + z_{0,9}\,\sigma}, \tag{9}$$

où Φ est la fonction de répartition de la loi normale centrée réduite et $z_{0,9}$ son quantile d'ordre $0{,}9$.

4.2.2 Disponibilité

La disponibilité intrinsèque (asymptotique) d'un moteur réparé après chaque défaillance est

$$A_\infty = \frac{\mathrm{MUT}}{\mathrm{MUT} + \mathrm{MDT}}, \tag{10}$$

avec $\mathrm{MUT} = \mathrm{MTTF}$ et $\mathrm{MDT} = \mathrm{MTTR}$ exprimés en cycles ; le MTBF vaut $\mathrm{MUT} + \mathrm{MDT}$. L'évolution de la disponibilité instantanée est décrite par le modèle markovien à deux états (marche, panne), de taux $\lambda = 1/\mathrm{MTTF}$ et $\mu = 1/\mathrm{MTTR}$:

$$A(t) = \frac{\mu}{\lambda + \mu} + \frac{\lambda}{\lambda + \mu}\, e^{-(\lambda + \mu)\,t}. \tag{11}$$

Ce modèle suppose des taux constants. Il s'agit d'une **approximation** : la loi retenue a un taux de défaillance croissant. Elle donne cependant la bonne limite A_∞ et illustre la convergence.

4.2.3 Politique de remplacement préventif à âge fixe

Selon la politique de Barlow et Proschan [16], un moteur est remplacé préventivement à l'âge T s'il n'a pas défailli avant, pour un coût C_p ; une défaillance en service coûte $C_c > C_p$. Par le théorème du renouvellement, le coût moyen par cycle vaut

$$C(T) = \frac{C_p\, R(T) + C_c\,\big(1 - R(T)\big)}{\displaystyle\int_0^T R(t)\,\mathrm{d}t}, \qquad C_\infty = \frac{C_c}{\mathrm{MTTF}}, \tag{12}$$

où C_∞ est le coût de la maintenance corrective seule. L'âge optimal T^* minimise $C(T)$; il est recherché numériquement au-delà de γ. Les coûts relatifs sont $C_p = 1$ et $C_c = 5$: une défaillance en service coûte autant que cinq remplacements préventifs. Ce rapport est une hypothèse d'illustration.

4.3 Sélection des capteurs et indicateur de santé (PDM-01, Salma)

4.3.1 Sélection des capteurs

Après le retrait des capteurs constants (section 3.4), deux scores sont calculés pour chaque capteur, en s'inspirant de Coble et Hines [17]. La **tendance** est la corrélation moyenne, sur les moteurs d'entraînement, entre le capteur et le numéro de cycle ; son signe indique le sens de la dérive. La **monotonie**, calculée sur la série lissée de chaque moteur, vaut

$$\mathrm{Mon} = \frac{\left|\#\{\Delta x > 0\} - \#\{\Delta x < 0\}\right|}{n - 1}. \tag{13}$$

Un capteur est retenu si sa tendance vérifie $|\rho| \geq 0{,}5$. La monotonie est calculée et affichée, mais n'entre pas dans la règle de sélection.

4.3.2 Features fenêtrées

Pour chaque capteur retenu et chaque cycle, trois features sont calculées sur une fenêtre glissante de $w = 10$ cycles, **moteur par moteur** pour qu'aucune fenêtre ne déborde sur le moteur précédent : la moyenne, l'écart-type et la pente locale des moindres carrés. Aux premiers cycles, la moyenne et l'écart-type utilisent les cycles disponibles et la pente vaut zéro tant que la fenêtre n'est pas complète. Avec l'indicateur de santé et le numéro de cycle, chaque cycle est décrit par 38 features.

4.3.3 Indicateur de santé

Suivant Wang et al. [18], l'indicateur de santé est une combinaison linéaire des capteurs retenus standardisés z_j :

$$\mathrm{HI}(t) = a_0 + \sum_j a_j \, z_j(t). \tag{14}$$

Les coefficients sont estimés par moindres carrés avec une cible égale à un sur les 10 % premiers cycles de chaque moteur d'entraînement (état sain) et à zéro sur les 10 % derniers (état défaillant) ; les cycles intermédiaires ne servent pas à l'ajustement. L'indicateur brut est ensuite lissé par une moyenne glissante de 10 cycles, moteur par moteur.

4.4 Classification de l'état de santé (PDM-02, Eya)

Un cycle est étiqueté **critique** si le RUL réel est inférieur ou égal à 30 cycles, durée choisie comme fenêtre d'intervention pour planifier un remplacement. Deux classifieurs de la bibliothèque scikit-learn [28] sont comparés sur les features du section 4.3 :

- un **gradient boosting** à histogrammes [29, 30] (300 itérations, pas d'apprentissage 0,05, 31 feuilles au plus par arbre), qui gère bien des features hétérogènes ;
- une **machine à vecteurs de support** à noyau gaussien [31] ($C = 3$), dont les sorties sont calibrées en probabilités par la méthode de Platt [32]. Le coût d'apprentissage du SVM étant quadratique en

nombre d'exemples, il est entraîné sur un sous-échantillon aléatoire de 6 000 cycles.

Validation sans fuite. Les cycles d'un même moteur sont fortement corrélés. Une validation croisée aléatoire placerait des cycles d'un même moteur à la fois dans l'apprentissage et dans la validation, ce qui surestimerait les performances. La validation croisée est donc faite **par groupes de moteurs** (GroupKFold, 5 plis) : chaque moteur est entièrement dans l'apprentissage ou entièrement dans la validation. Le modèle de meilleure AUC sur le jeu de test sert ensuite à classer chaque moteur en service, selon la probabilité p d'état critique à son dernier cycle : *critique* si $p \geq 0{,}5$, *surveillance* si $p \geq 0{,}2$, *normal* sinon.

4.5 Estimation du RUL par modèle de dégradation bayésien (RUL-01, Eya)

4.5.1 Modèle

L'indicateur de santé brut d'un moteur est modélisé par un polynôme de degré 2 du temps réduit $\tau = t/100$, à coefficients propres au moteur :

$$\mathrm{HI}(t) = \boldsymbol{\phi}(t)^{\top}\mathbf{w} + \varepsilon, \qquad \boldsymbol{\phi}(t) = (1, \tau, \tau^2)^{\top}, \qquad \varepsilon \sim \mathcal{N}(0, \sigma^2). \tag{15}$$

4.5.2 Apprentissage sur la flotte : loi a priori

Le polynôme est ajusté par moindres carrés sur chaque moteur d'entraînement. La moyenne $\mathbf{m}_0$ et la covariance $\mathbf{S}_0$ des coefficients obtenus définissent la loi a priori $\mathbf{w} \sim \mathcal{N}(\mathbf{m}_0, \mathbf{S}_0)$, qui représente la variabilité de la flotte [19]. La variance du bruit σ^2 est celle des résidus. Le **seuil de défaillance** est la valeur moyenne du HI ajusté au cycle de défaillance, et son écart-type sur la flotte mesure l'incertitude du seuil.

4.5.3 Mise à jour bayésienne pour un moteur en service

Pour un moteur observé aux instants $t_1, \ldots, t_n$, de matrice de régression $\boldsymbol{\Phi}$ et de mesures $\mathbf{h}$, le modèle étant gaussien et linéaire en $\mathbf{w}$, la loi a posteriori est gaussienne (conjugaison) :

$$\mathbf{S}_n^{-1} = \mathbf{S}_0^{-1} + \frac{\boldsymbol{\Phi}^{\top}\boldsymbol{\Phi}}{\sigma^2}, \qquad \mathbf{m}_n = \mathbf{S}_n\left(\mathbf{S}_0^{-1}\mathbf{m}_0 + \frac{\boldsymbol{\Phi}^{\top}\mathbf{h}}{\sigma^2}\right). \tag{16}$$

Au début de la vie, l'a priori de flotte domine ; quand les mesures s'accumulent, la trajectoire propre du moteur prend le dessus.

4.5.4 Distribution du RUL

On tire 1 000 vecteurs de coefficients dans la loi a posteriori et, pour chacun, un seuil dans $\mathcal{N}(\bar{s}, \sigma_s^2)$. Chaque trajectoire moyenne est prolongée cycle par cycle sur un horizon de 400 cycles, et l'instant de premier passage sous le seuil donne un RUL. La médiane de ces RUL est la prédiction ; leurs quantiles donnent les intervalles de prédiction (P10–P90, et pour la calibration P25–P75 et P05–P95). Le bruit ε n'est pas ajouté aux trajectoires : l'incertitude représentée est celle des coefficients et du seuil. Ce choix a une conséquence sur la largeur des intervalles, discutée au section 8.2.

4.6 Estimation du RUL par réseau LSTM (RUL-02, Salma)

4.6.1 Données d'entrée et cible

Les 12 capteurs retenus sont normalisés entre zéro et un avec les minimums et maximums du jeu d'entraînement. Chaque exemple est une fenêtre de 30 cycles consécutifs d'un même moteur ; la cible est le RUL au dernier cycle de la fenêtre. Une série plus courte que la fenêtre est complétée au début en répétant sa première ligne. Suivant une convention établie sur C-MAPSS [21], la cible est **plafonnée** :

$$y = \min(\mathrm{RUL}, 125), \tag{17}$$

car en début de vie la dégradation n'est pas observable et le RUL exact ne peut pas être appris.

4.6.2 Architecture et apprentissage

Le réseau [22, 23] comprend 2 couches LSTM de 64 unités avec un dropout de 0,2, puis une petite couche dense ReLU et une sortie linéaire. L'apprentissage minimise l'erreur quadratique moyenne avec l'optimiseur Adam [33] (pas initial 0,001, lots de 256 fenêtres, écrêtage de la norme du gradient), et le pas est réduit en cas de plateau. 15 moteurs d'entraînement tirés au hasard sont réservés à la validation. L'**arrêt précoce** interrompt l'apprentissage après 8 époques sans amélioration de l'erreur de validation (au plus 60 époques), et les poids de la meilleure époque sont conservés. La prédiction pour un moteur de test est la sortie au dernier cycle observé, bornée à zéro. Le réseau est implémenté avec PyTorch [34].

Reproductibilité. L'entraînement du LSTM n'est pas exactement reproductible d'une machine à l'autre (calcul flottant sur processeur). Les résultats publiés correspondent au modèle sauvegardé, rechargé par défaut ; le réentraînement reste possible et sa variabilité est quantifiée au section 5.4.

5 Architecture et workflow du système

5.1 Pipeline de calcul

Le code Python est organisé en modules, un par ticket du plan de sprints (répartition en annexe, « Annexe D — Répartition du travail »). Le script `run_all.py` enchaîne toutes les étapes et exporte les résultats dans des fichiers JSON, qui sont l'unique source de vérité du tableau de bord, des figures, des tableaux et des chiffres de ce rapport :

```
data/raw/*.txt
   │  data.py           chargement, RUL, table de durées de vie, description du jeu
   ▼
fmds.py                 fiabilité, maintenabilité, disponibilité, préventif
features.py             capteurs, features fenêtrées, indicateur de santé
health.py               classification normal / critique
rul_degradation.py      modèle de dégradation bayésien
rul_lstm.py             réseau LSTM
   ▼
results/  fmds.json  health.json  rul.json  engines.json  dataset.json  run_info.json
   ├──► api/main.py (FastAPI)  ──►  tableau de bord React
   ├──► report_figures.py      ──►  report/figures   (PNG et PDF)
   └──► report_tables.py       ──►  report/tables, report/generated/valeurs.json
```

Les modèles entraînés sont sauvegardés dans `backend/models/`. Sur la machine de développement, la chaîne complète s'exécute en un peu moins d'une minute lorsque le LSTM de référence est rechargé.

5.2 API et endpoints

L'API est développée avec FastAPI (ticket WEB-01, Eya). Elle lit les fichiers JSON, les garde en mémoire et expose cinq routes en lecture :

- `/api/fmds` : indices de fiabilité, de maintenabilité et de disponibilité, et politique préventive ;
- `/api/health` : sélection des capteurs, indicateur de santé et performances des classifieurs ;
- `/api/rul` : métriques, calibration et prédictions des deux modèles de RUL ;
- `/api/fleet` : état actuel des moteurs de test (tableau de flotte) ;
- `/api/engines/{id}` : historique complet d'un moteur de test (indicateur de santé, probabilité d'état critique, RUL prédit à chaque cycle).

Un identifiant de moteur hors de la plage connue renvoie une erreur `404`, un identifiant non numérique une erreur `422`, et l'absence des résultats une erreur `503` avec un message explicite. La documentation interactive (Swagger) est générée automatiquement. La même application sert le tableau de bord compilé ; elle refuse toute requête qui tenterait de sortir du dossier du tableau de bord.

5.3 Tableau de bord

Le tableau de bord (ticket WEB-02, Salma) est une application React avec des graphiques Recharts. Il comporte quatre pages : la vue d'ensemble (figure 3), la fiabilité et les indices FMDS (figure 4), le suivi de l'état de santé (figure 5) et la durée de vie résiduelle (figure 6). Une version **autonome** en un seul fichier HTML, avec les résultats intégrés, s'ouvre sans serveur ni installation, ce qui facilite la démonstration et la diffusion.

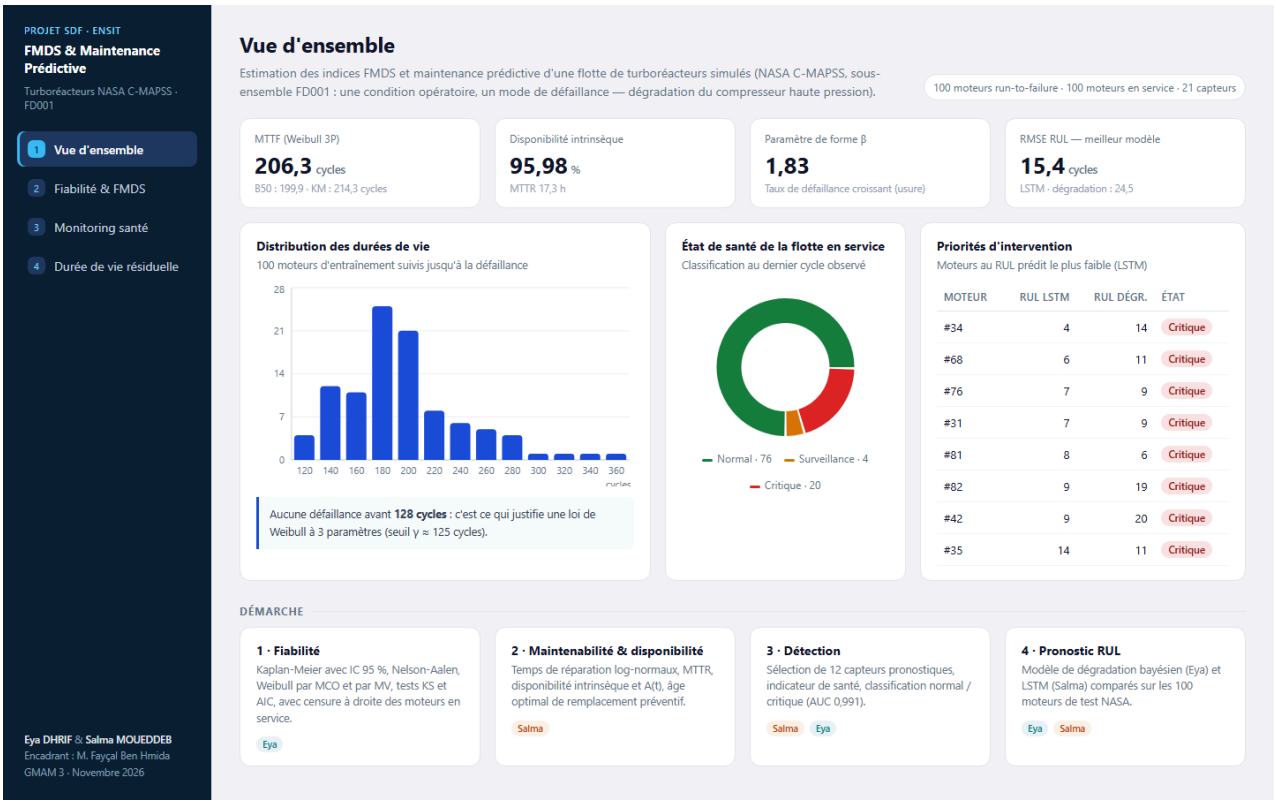


Figure 3 – Page « Vue d'ensemble » : indicateurs clés, distribution des durées de vie, état de la flotte en service et priorités d'intervention.



Figure 4 – Page « Fiabilité & FMDS » : fonction de fiabilité, paramètres estimés, adéquation des lois, maintenabilité, disponibilité et politique préventive.

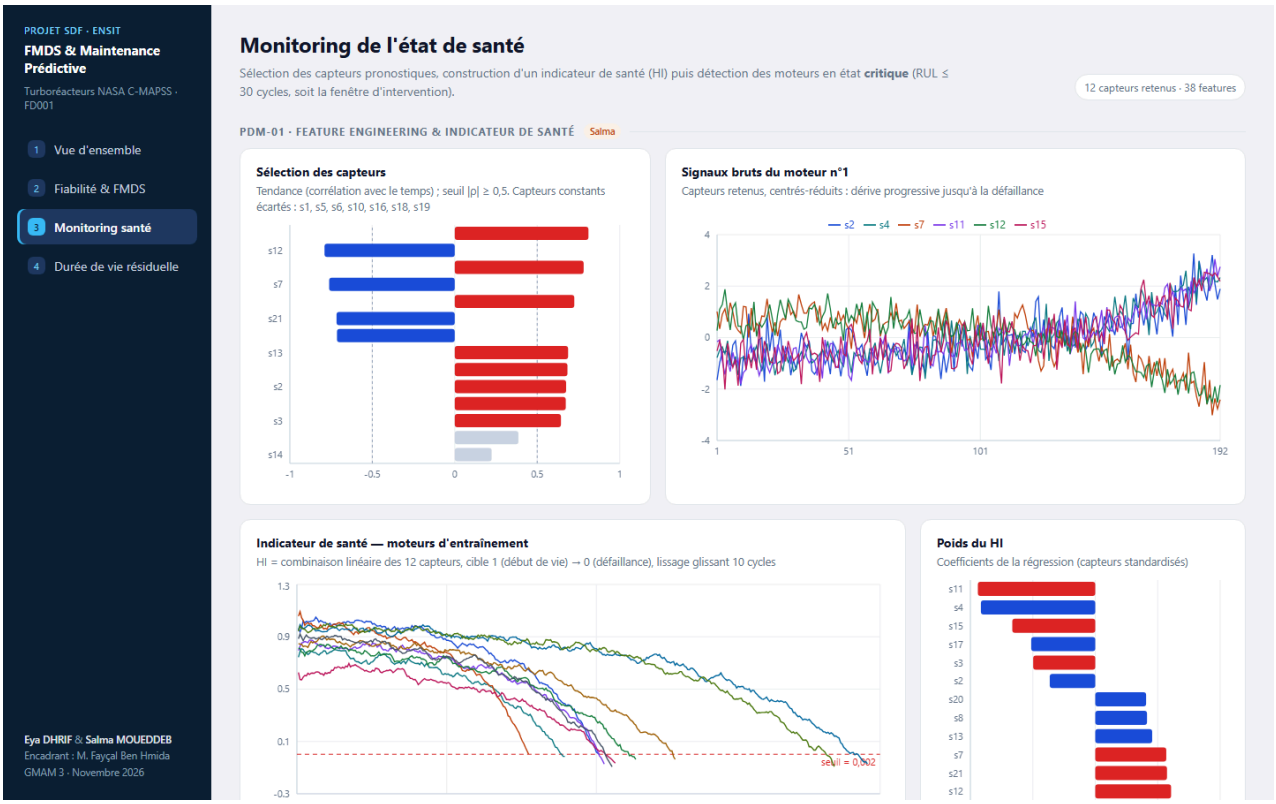


Figure 5 – Page « Monitoring santé » : sélection des capteurs, indicateur de santé, performances de la classification et suivi d'un moteur.

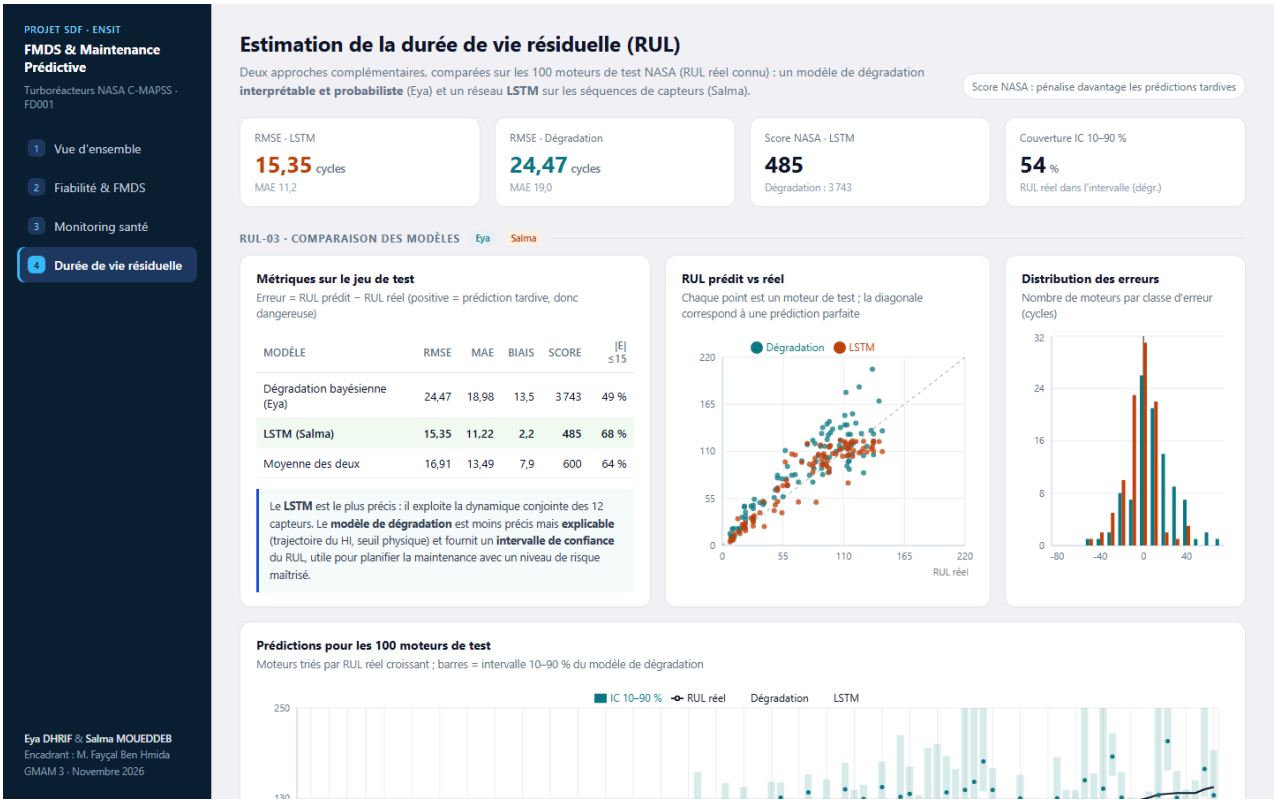


Figure 6 – Page « Durée de vie résiduelle » : métriques des deux modèles, prédictions pour la flotte, calibration et analyse moteur par moteur.

5.4 Reproductibilité et qualité

Plusieurs dispositifs garantissent que chaque chiffre est reproductible et traçable :

- **graines fixées** pour toutes les étapes aléatoires (temps de réparation simulés, classifieurs, tirages du modèle de dégradation, LSTM) ;
- **modèle LSTM de référence** : un réentraînement sur une autre machine a donné un RMSE légèrement différent, dans la tolérance fixée de plus ou moins un demi-cycle. Les résultats publiés correspondent donc au modèle sauvegardé, que `run_all.py` recharge par défaut ; toutes les autres étapes sont déterministes, et deux exécutions produisent des fichiers JSON identiques ;
- **traçabilité** : chaque exécution écrit la date, la durée, les versions des bibliothèques et les graines dans `run_info.json`. Les résultats de ce rapport ont été produits avec Python 3.12.10, NumPy 2.5.4, pandas 2.3.3, scikit-learn 1.9.1, lifelines 0.30.3 et PyTorch 2.15.0 ;
- **suite de tests automatiques** (pytest pour le calcul et l'API, Playwright pour le tableau de bord). Elle vérifie les méthodes sur des cas dont la réponse est connue, la non-régression de chaque chiffre, l'absence de fuite entre moteurs, la cohérence entre l'API, les fichiers et le tableau de bord, et la concordance de chaque nombre de ce rapport avec sa source.

6 Protocole expérimental et métriques

6.1 Découpages des données et validation

Le découpage officiel de FD001 est respecté : les modèles sont appris sur les 100 moteurs d'entraînement et évalués sur les 100 moteurs de test, jamais vus pendant l'apprentissage. Les choix propres à chaque partie sont les suivants :

- **fiabilité** : population de 200 unités, avec 100 défaillances et 100 censures à droite (section 3.3) ; le RUL réel des moteurs de test n'est pas utilisé ;
- **classification** : validation croisée par groupes de moteurs (5 plis) sur l'entraînement, puis évaluation sur **tous les cycles** des moteurs de test ;
- **RUL** : évaluation au **dernier cycle observé** de chaque moteur de test, comme dans le challenge PHM [2] ; le LSTM réserve 15 moteurs d'entraînement à l'arrêt précoce.

6.2 Métriques

6.2.1 Fiabilité

Le test de Kolmogorov-Smirnov accepte une loi si sa p-valeur dépasse $\alpha = 5\,\%$. L'AIC compare les lois entre elles, et le coefficient R^2 mesure la linéarité du diagramme de Weibull (section 4.1).

6.2.2 Classification

Avec VP, FP, VN et FN les vrais et faux positifs et négatifs (la classe positive étant l'état critique), on utilise :

$$\text{précision} = \frac{VP}{VP + FP}, \qquad \text{rappel} = \frac{VP}{VP + FN}, \qquad F_1 = \frac{2\,\text{précision}\cdot\text{rappel}}{\text{précision} + \text{rappel}}. \tag{18}$$

En maintenance, le **rappel** est la métrique la plus importante, car une défaillance manquée coûte bien plus cher qu'une inspection inutile. L'aire sous la courbe ROC (AUC) [35] mesure la capacité à classer un cycle critique au-dessus d'un cycle normal, indépendamment du seuil de décision.

6.2.3 Durée de vie résiduelle

L'erreur d'un moteur est $e_i = \widehat{\mathrm{RUL}}_i - \mathrm{RUL}_i$: une erreur **positive** est une prédiction **tardive**, la plus dangereuse puisqu'elle annonce plus de vie qu'il n'en reste. Sur les N moteurs de test :

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i} e_i^2}, \qquad \mathrm{MAE} = \frac{1}{N}\sum_{i} |e_i|, \qquad \text{biais} = \frac{1}{N}\sum_{i} e_i. \tag{19}$$

Le **score NASA** [2] pénalise exponentiellement les erreurs, et davantage les prédictions tardives :

$$S = \sum_{i} s_i, \qquad s_i = \begin{cases} e^{-e_i/13} - 1 & e_i < 0 \\ e^{e_i/10} - 1 & e_i \geq 0 \end{cases}. \tag{20}$$

Pour le modèle de dégradation, la qualité de l'incertitude est mesurée par la **couverture empirique** : la proportion de moteurs dont le RUL réel tombe dans l'intervalle de prédiction. Un intervalle bien calibré de niveau nominal q couvre le RUL réel dans une proportion proche de q ; une couverture inférieure signale une incertitude sous-estimée. Trois niveaux sont évalués : P25–P75, P10–P90 et P05–P95.

7 Résultats

Tous les chiffres de ce chapitre proviennent des fichiers de résultats produits par `run_all.py` ; les figures et les tableaux sont générés à partir de ces fichiers.

7.1 Fiabilité

7.1.1 Estimation non paramétrique

La courbe de Kaplan-Meier (figure 7) vaut un jusqu'à la première défaillance, puis décroît rapidement. La médiane de survie est de 202 cycles et l'aire sous la courbe de 214,3 cycles. Les censures (moteurs de test) se concentrent aux faibles âges, où presque toute la population est encore à risque ; elles élargissent peu l'intervalle de confiance, qui ne s'ouvre vraiment qu'aux grands âges, quand peu de moteurs restent à risque.

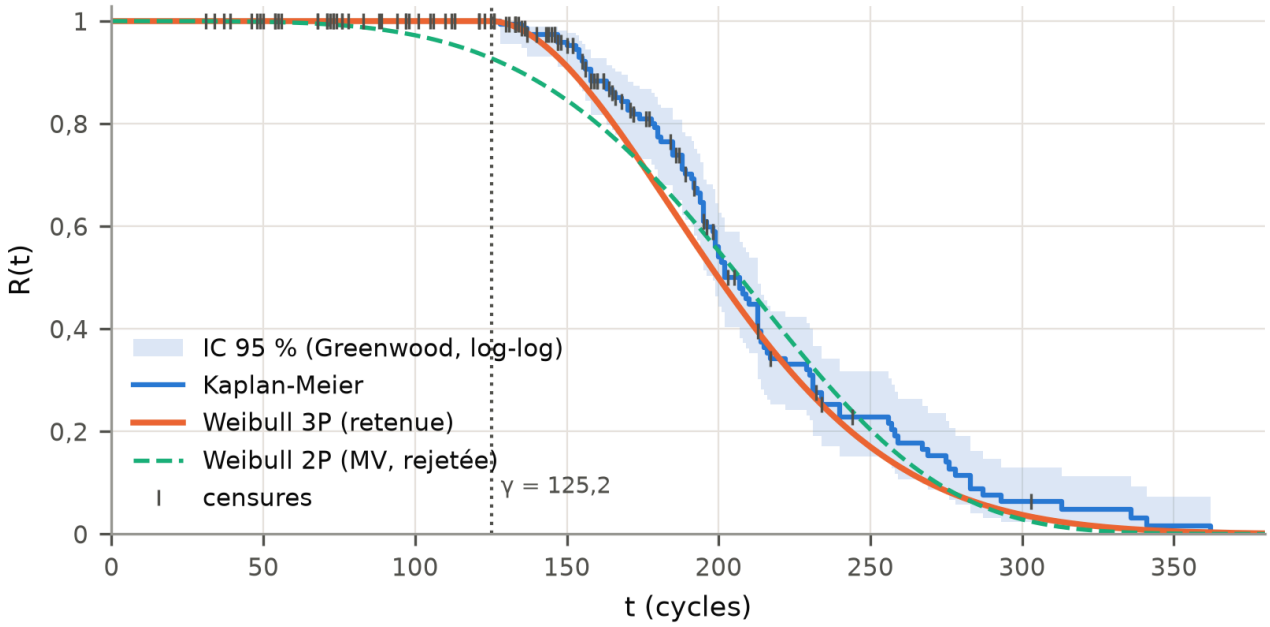


Figure 7 – Fonction de fiabilité : estimateur de Kaplan-Meier avec son intervalle de confiance et les censures, comparé à la loi de Weibull 3P retenue et à la loi de Weibull 2P (MV) rejetée.

Le taux de défaillance estimé par Nelson-Aalen (figure 8) est nul jusqu'à l'âge de la première défaillance, puis croît : c'est la signature d'une **usure**. Ses oscillations aux grands âges reflètent le faible nombre de moteurs encore à risque et non un phénomène physique.

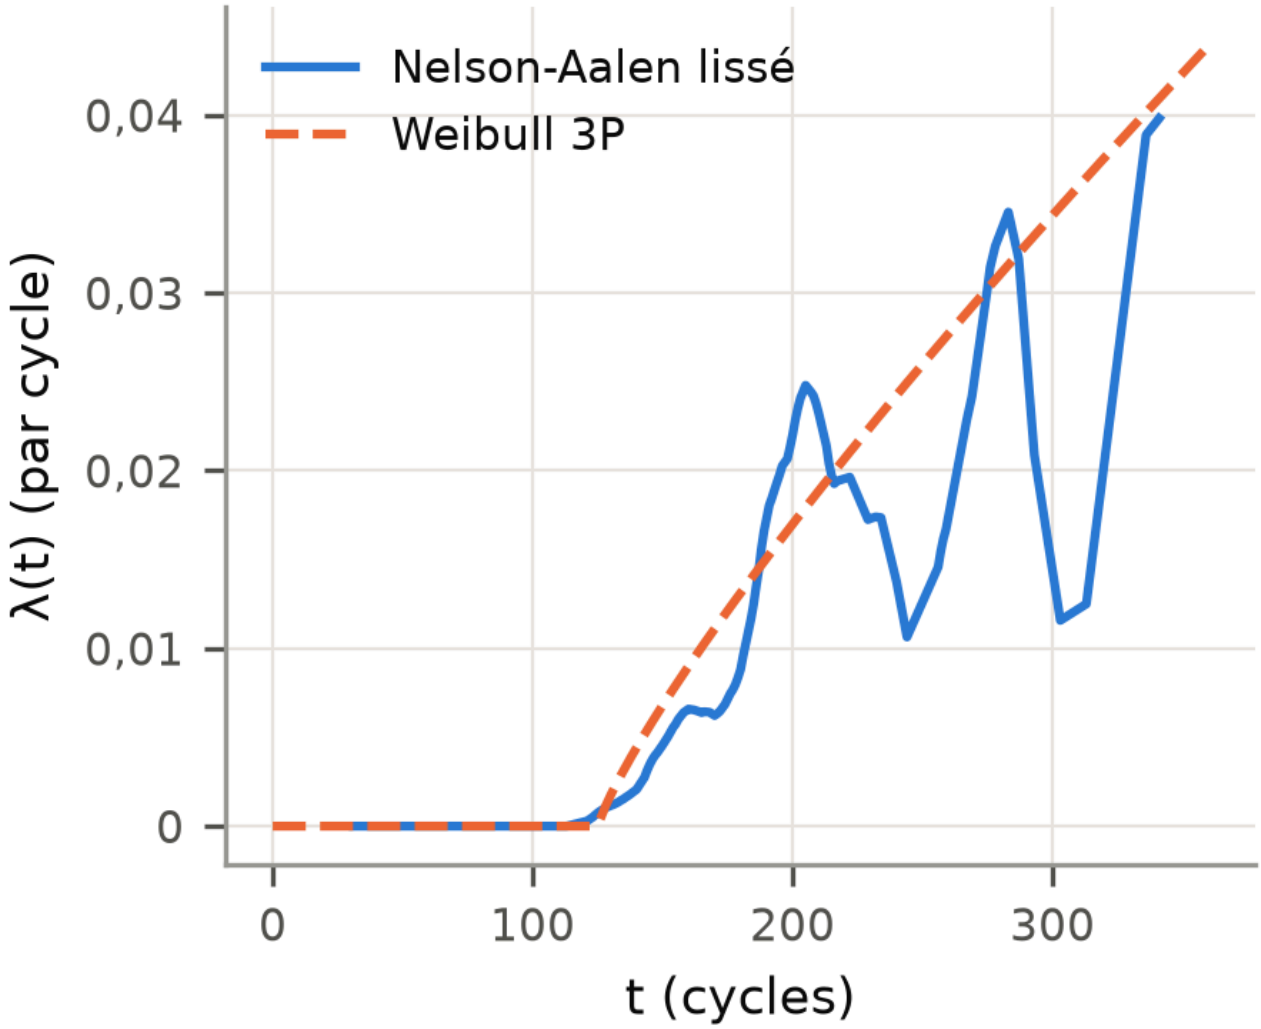


Figure 8 – Taux de défaillance : estimation non paramétrique de Nelson-Aalen lissée par noyau et taux de la loi de Weibull 3P.

7.1.2 Choix de la loi

Le tableau 3 et le tableau 4 résument les ajustements. Le diagramme de Weibull (figure 9) est nettement **courbé** : les points s'écartent de la droite aux deux extrémités et le coefficient de détermination ne vaut que 0,894. La pente donne $\beta = 5{,}52$ par MCO. L'estimation par MV de la loi de Weibull 2P sur les défaillances donne $\beta = 4{,}41$, mais elle est **rejetée** par le test de Kolmogorov-Smirnov ($p = 0{,}013$). Avec la censure, l'estimation sur les 200 unités donne $\beta = 4{,}82$ (intervalle de confiance $[4{,}22 ; 5{,}42]$) et $\eta = 236{,}6$ cycles : l'échelle est plus grande, car les moteurs censurés apportent l'information qu'ils ont survécu au moins jusqu'à leur dernier cycle observé.

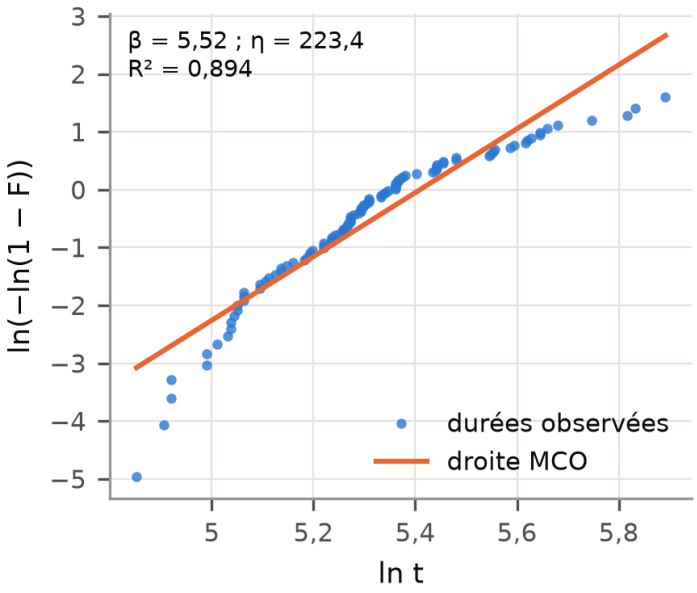


Figure 9 – Diagramme de Weibull (rangs médians de Bernard) et droite des moindres carrés : la courbure révèle un paramètre de position non nul.

Tableau 3 – Modèles de fiabilité estimés sur les 100 durées de défaillance

Méthode	β	η (cycles)	γ (cycles)	Adéquation	Décision
Weibull 2P, MCO (rangs de Bernard)	5,52	223,4	0	R^2 = 0,894	diagramme courbé
Weibull 2P, MV	4,41	225,0	0	KS p = 0,013	rejetée
Weibull 2P, MV avec censure (200 unités)	4,82 [4,22 ; 5,42]	236,6	0	—	comparaison
Weibull 3P, MV	**1,83**	**91,3**	**125,2**	KS p = 0,32	**retenue**

Tableau 4 – Adéquation des lois candidates (MV sur les durées complètes)

Loi	Paramètres	Log-vraisemblance	AIC	KS D	KS p	Décision (α = 5 %)
Exponentielle	1	−632,94	1 267,88	0,470	0,000	rejetée
Weibull 2P	2	−530,75	1 065,50	0,157	0,013	rejetée
Log-normale	2	−517,46	1 038,91	0,094	0,317	acceptée
Weibull 3P	3	−516,52	1 039,03	0,094	0,319	acceptée

La loi exponentielle est rejetée sans ambiguïté ($p = 0{,}000$, AIC 1 267,88), ce qui exclut un taux de défaillance constant. Les lois de Weibull 3P (AIC 1 039,03, $p = 0{,}32$) et log-normale (AIC 1 038,91, $p = 0{,}32$) sont toutes deux acceptées, avec une différence d'AIC de 0,12 seulement : elles sont **statistiquement équivalentes**, et toutes deux bien meilleures que la loi de Weibull 2P (AIC 1 065,50). La loi de **Weibull 3P est retenue** pour trois raisons :

1. son paramètre de position $\gamma = 125{,}2$ cycles a une interprétation physique directe, la durée de fonctionnement sans défaillance garantie, cohérente avec la première défaillance observée à 128 cycles ;
2. son paramètre de forme $\beta = 1{,}83 > 1$ traduit un taux de défaillance croissant, conforme à l'estimation non paramétrique ;
3. elle est la loi de référence du cours et de la fiabilité mécanique [5, 12].

7.1.3 Indicateurs de fiabilité

Le tableau 5 donne les indicateurs du modèle retenu : MTTF de 206,3 cycles, $B_1 = 132{,}6$, $B_{10} = 151{,}9$ et $B_{50} = 199{,}9$ cycles. La durée B_{50} est proche de la médiane de Kaplan-Meier (202 cycles), ce qui confirme l'accord entre les deux approches au centre de la distribution. La densité et la fonction de répartition (figure 10) montrent une distribution concentrée entre la fin de la période sans défaillance et les âges de l'ordre de trois cents cycles.

Tableau 5 – Indicateurs de fiabilité

Indicateur	Valeur	Source
MTTF = γ + η·Γ(1 + 1/β)	206,3 cycles	Weibull 3P
B1 (1 % de défaillances)	132,6 cycles	Weibull 3P
B10 (10 %)	151,9 cycles	Weibull 3P
B50 (médiane)	199,9 cycles	Weibull 3P
Médiane de survie	202 cycles	Kaplan-Meier
Aire sous la courbe de survie	214,3 cycles	Kaplan-Meier
Première défaillance observée	128 cycles	données

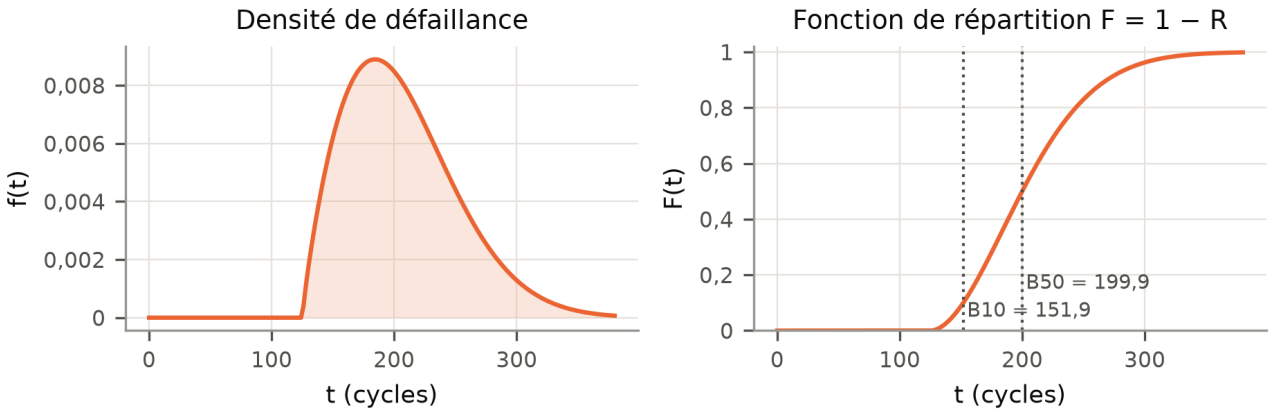


Figure 10 – Densité de défaillance et fonction de répartition de la loi de Weibull 3P, avec les durées B10 et B50.

La fiabilité conditionnelle (figure 11) vaut un tant que l'âge augmenté de l'horizon reste dans la période sans défaillance, puis décroît : un moteur âgé a une probabilité de plus en plus faible de franchir les 25 cycles suivants. Ce résultat justifie directement une politique de remplacement liée à l'âge.

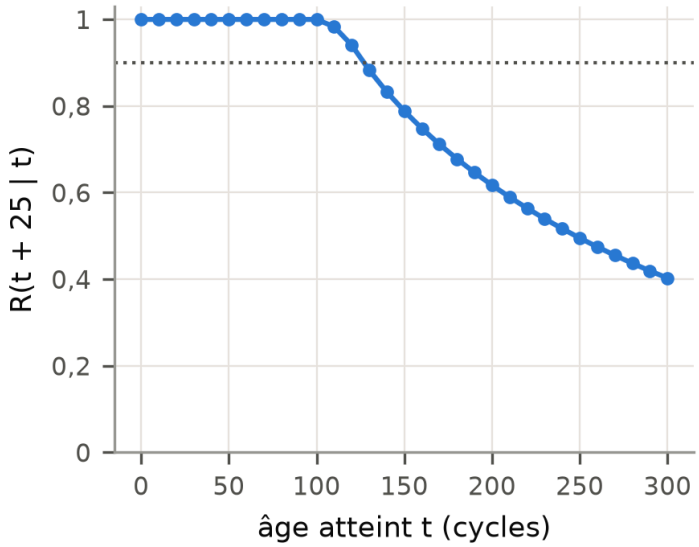


Figure 11 – Fiabilité conditionnelle : probabilité qu'un moteur ayant atteint l'âge t fonctionne encore pendant l'horizon suivant (ligne pointillée : niveau 0,9).

7.2 Maintenabilité, disponibilité et politique préventive

Ces résultats reposent sur les temps de réparation simulés (section 4.2). La loi log-normale ré-estimée sur l'échantillon a pour paramètres $\mu = 2{,}742$ et $\sigma = 0{,}464$; le test de Kolmogorov-Smirnov l'accepte ($p = 0{,}61$). L'écart-type estimé est inférieur à la valeur utilisée pour la simulation (0,6) : c'est l'effet de la fluctuation d'échantillonnage sur un échantillon de cette taille. Le MTTR vaut 17,3 h, soit 8,6 cycles, et 90 % des réparations sont terminées en 28,1 h (figure 12).

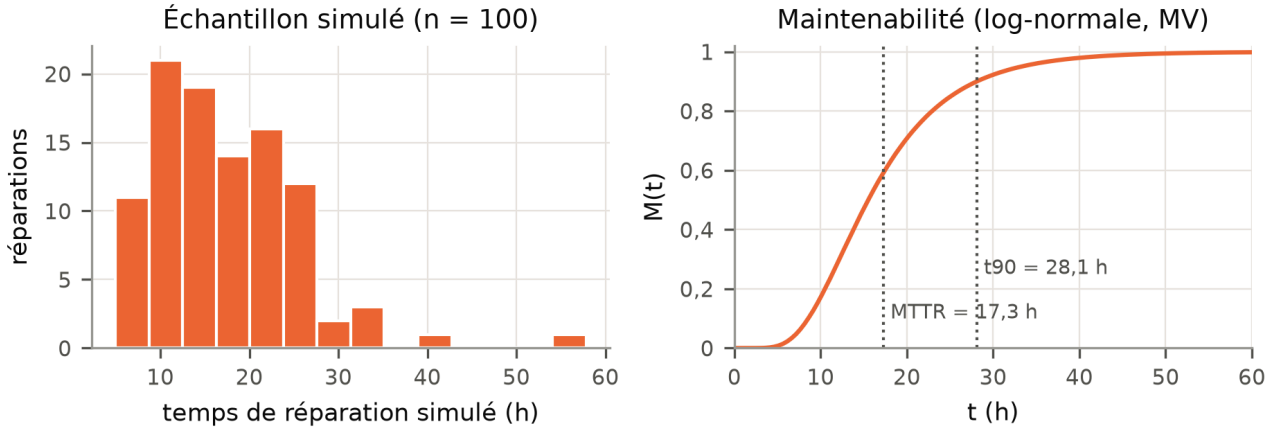


Figure 12 – Temps de réparation simulés (gauche) et fonction de maintenabilité de la loi log-normale estimée, avec le MTTR et la durée t90 (droite).

Le tableau 6 regroupe les indicateurs. La disponibilité intrinsèque vaut **95,98 %**, soit environ 40,2 h d'indisponibilité pour mille heures. Selon le modèle markovien (figure 13), la disponibilité instantanée part de un et converge vers cette valeur en quelques dizaines de cycles.

Tableau 6 – Maintenabilité, disponibilité et remplacement préventif (temps de réparation simulés)

Grandeur	Valeur
Loi des temps de réparation (MV)	log-normale, μ = 2,742, σ = 0,464 (KS p = 0,61)
MTTR	17,3 h = 8,6 cycles
t90 (90 % des réparations terminées)	28,1 h
MUT / MDT / MTBF	206,3 / 8,64 / 215,0 cycles
Disponibilité intrinsèque A = MUT / (MUT + MDT)	95,98 %
Âge optimal de remplacement T*	130,7 cycles, R(T*) = 0,994
Coût par cycle : à T* / corrective seule	0,0078 / 0,0242 (unités de Cp)
Gain du préventif	67,7 %

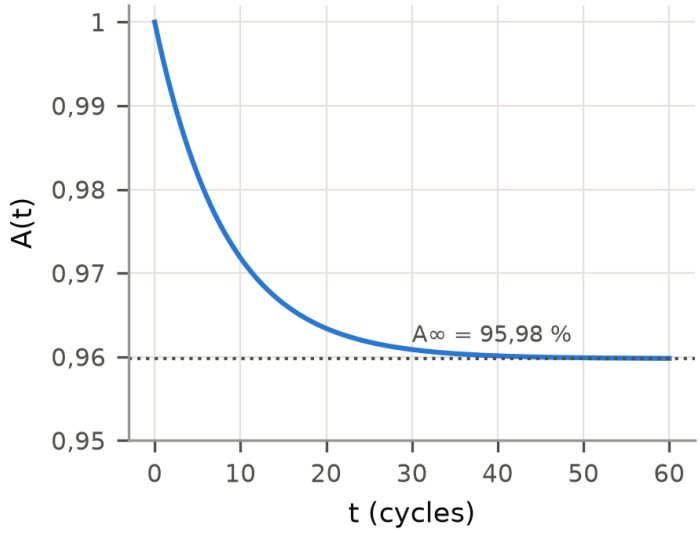


Figure 13 – Disponibilité instantanée A(t) selon le modèle markovien à deux états et sa limite asymptotique.

La politique de remplacement préventif (figure 14) présente un optimum net à $T^* = 130{,}7$ cycles, juste après la fin de la période sans défaillance. À cet âge, la fiabilité vaut encore 0,994 : presque aucun moteur ne défaille en service. Le coût par cycle passe de 0,0242 (maintenance corrective seule) à 0,0078, soit une **réduction de 68 %**. Le prix de ce gain est élevé : chaque moteur est remplacé en moyenne 75,6 cycles avant son MTTF.

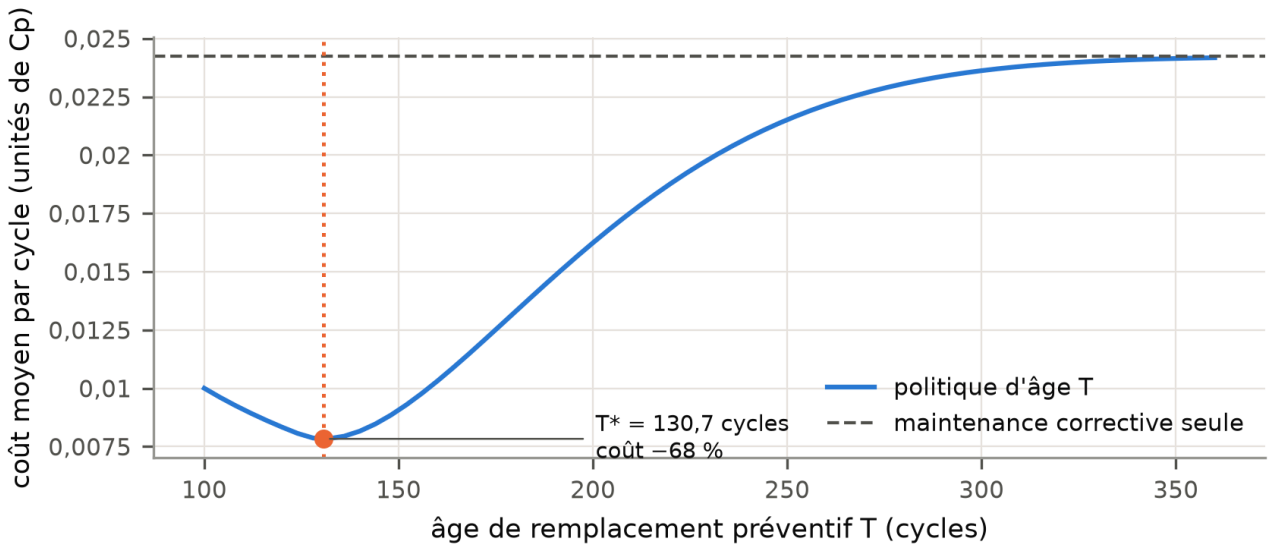


Figure 14 – Coût moyen par cycle de la politique de remplacement à âge fixe en fonction de l'âge T, comparé au coût de la maintenance corrective seule.

7.3 Indicateur de santé et détection de l'état critique

7.3.1 Sélection des capteurs et indicateur de santé

Parmi les capteurs non constants, 12 présentent une tendance supérieure en valeur absolue au seuil de 0,5 et sont retenus : s2, s3, s4, s7, s8, s11, s12, s13, s15, s17, s20, s21 (figure 15). Les capteurs s9 et s14, des vitesses de rotation du corps du moteur, ont une tendance plus faible et sont écartés.

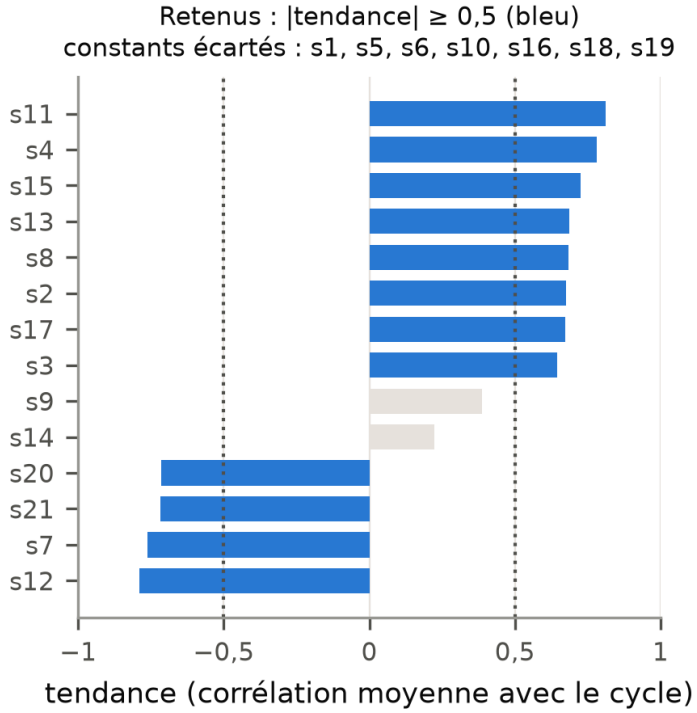


Figure 15 – Tendance des capteurs non constants : corrélation moyenne avec le numéro de cycle ; les capteurs retenus dépassent le seuil en valeur absolue.

L'indicateur de santé (figure 16) part d'environ un en début de vie et décroît jusqu'au voisinage de zéro à la défaillance, pour tous les moteurs, avec des durées de vie très différentes. Le seuil de défaillance appris par le modèle de dégradation vaut 0,002. Les poids de la combinaison linéaire (figure 17) sont de signes opposés selon le sens de dérive des capteurs ; les plus forts portent sur la pression statique en sortie du compresseur haute pression (s11) et sur la température en sortie de la turbine basse pression (s4).

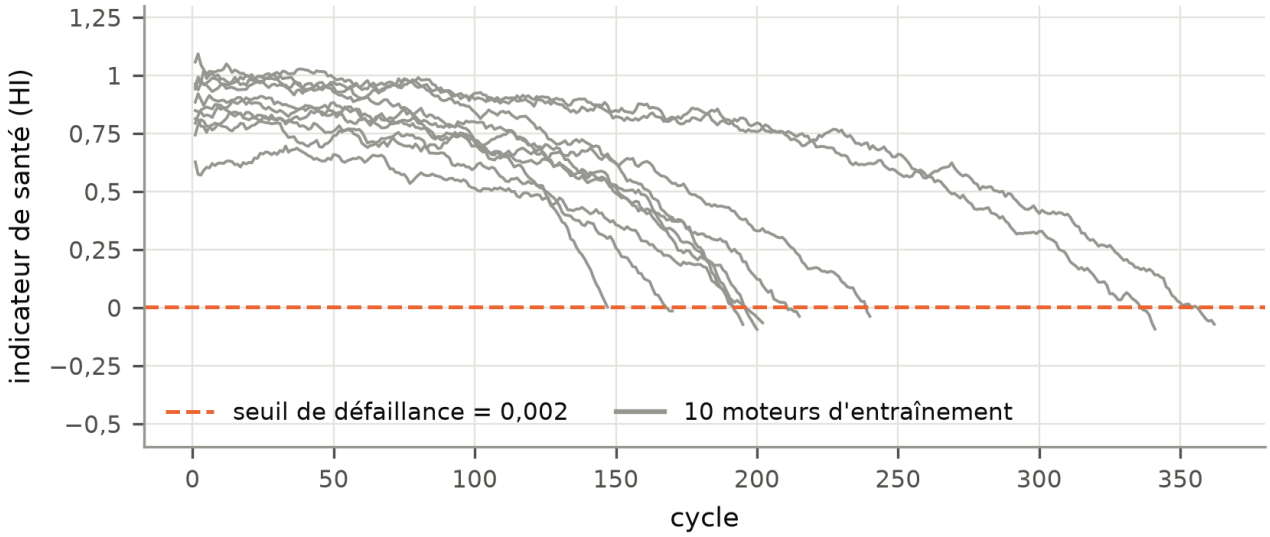


Figure 16 – Indicateur de santé lissé de dix moteurs d'entraînement et seuil de défaillance.

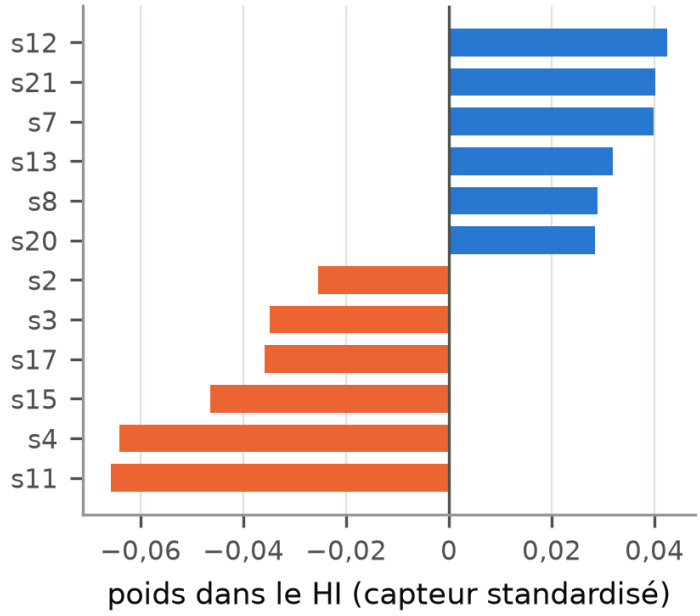


Figure 17 – Poids des capteurs standardisés dans l'indicateur de santé.

7.3.2 Classification normal / critique

Le tableau 7 présente les performances. Les deux classifieurs séparent très bien les deux classes : en validation croisée par groupes de moteurs, l'AUC vaut 0,990 pour le gradient boosting et 0,983 pour le SVM ; sur le jeu de test, 0,991 et 0,974 (figure 18). Le **gradient boosting** est retenu.

Tableau 7 – Classification normal / critique (RUL ≤ 30 cycles)

Modèle	Évaluation	AUC	Exactitude	Précision	Rappel	F1
Gradient Boosting	validation croisée (GroupKFold 5)	0,990	0,961	0,892	0,844	0,867
	test NASA	0,991	0,986	0,747	0,657	0,699
SVM (RBF)	validation croisée (GroupKFold 5)	0,983	0,958	0,879	0,824	0,851
	test NASA	0,974	0,986	0,798	0,621	0,698

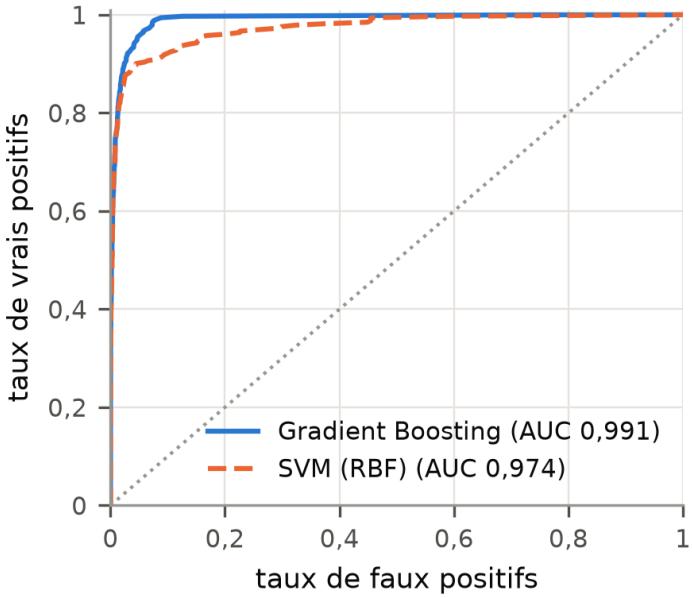


Figure 18 – Courbes ROC des deux classifieurs sur le jeu de test.

Au seuil de décision par défaut, le rappel de test est cependant nettement plus faible qu'en validation croisée (0,657 contre 0,844). La matrice de confusion (figure 19) montre que, sur les 332 cycles critiques du jeu de test, 218 sont détectés et 114 manqués, pour 74 fausses alertes parmi 12 690 cycles normaux correctement classés. Le jeu de test est très déséquilibré : la plupart des séries s'arrêtent bien avant la défaillance, et seuls les derniers cycles de quelques moteurs sont critiques. L'AUC élevée montre que le classement des probabilités reste bon ; c'est le **seuil** de décision qui est trop strict pour cet usage (section 8.2).

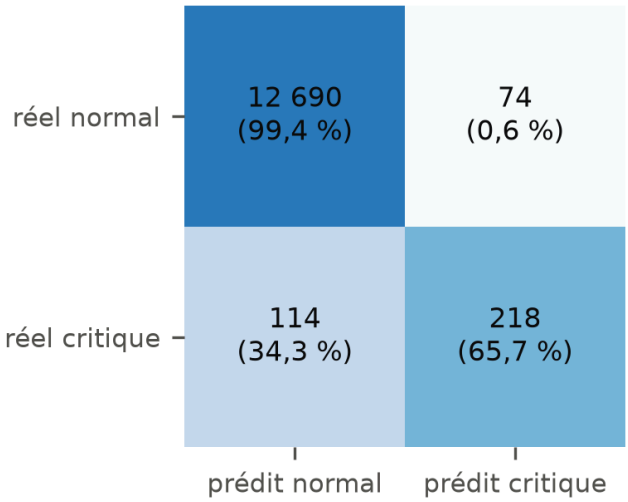


Figure 19 – Matrice de confusion du gradient boosting sur le jeu de test, au seuil de décision par défaut.

Au dernier cycle observé, la flotte de test se répartit en 76 moteurs normaux, 4 en surveillance et 20 critiques.

7.4 Durée de vie résiduelle

7.4.1 Performances des deux modèles

Le tableau 8 compare les modèles sur les 100 moteurs de test. Le **LSTM est le plus précis** sur toutes les métriques : RMSE de 15,35 cycles contre 24,47, MAE de 11,22 contre 18,98, et score NASA de 485 contre 3 743. Son biais est faible (+2,2 cycles), alors que le modèle de dégradation prédit en moyenne trop tard (+13,5 cycles, 78 % de prédictions tardives). Le score NASA, qui pénalise fortement les retards, amplifie cet écart. La moyenne des deux prédictions (RMSE 16,91) n'améliore pas le LSTM seul : le biais du modèle de dégradation l'emporte sur le gain de la combinaison.

Tableau 8 – Performances des modèles de RUL sur les 100 moteurs de test

Modèle	RMSE	MAE	Biais	Score NASA	|e| ≤ 15	Tardives
Dégradation bayésienne (Eya)	24,47	18,98	+13,5	3 743	49 %	78 %
LSTM (Salma)	15,35	11,22	+2,2	485	68 %	58 %
Moyenne des deux	16,91	13,49	+7,9	600	64 %	76 %

La figure 20 montre les prédictions en fonction du RUL réel. Les prédictions du LSTM suivent la diagonale jusqu'au plafond de 125 cycles, au-delà duquel il ne peut pas prédire ; celles du modèle de dégradation sont plus dispersées et majoritairement au-dessus de la diagonale. La distribution des erreurs (figure 21) confirme le décalage du modèle de dégradation vers les prédictions tardives.

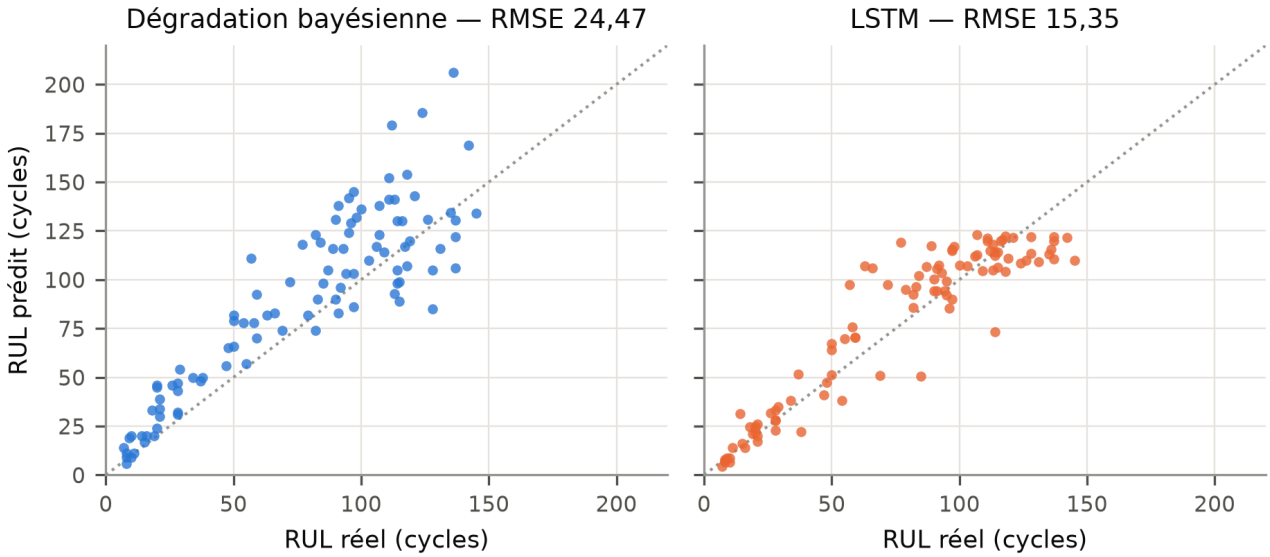


Figure 20 – RUL prédit en fonction du RUL réel pour les deux modèles ; la diagonale correspond à une prédiction parfaite.

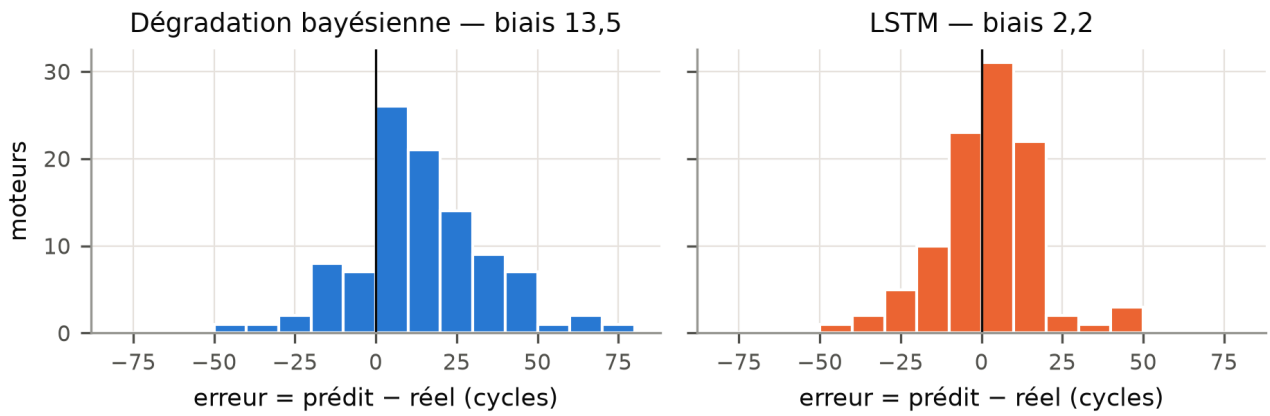


Figure 21 – Distribution des erreurs de prédiction ; une erreur positive est une prédiction tardive.

La figure 22 présente les prédictions pour l'ensemble de la flotte, triée par RUL réel croissant. Pour les moteurs proches de la défaillance, les deux modèles sont précis et les intervalles du modèle de dégradation sont étroits ; pour les moteurs encore jeunes, l'incertitude augmente fortement.

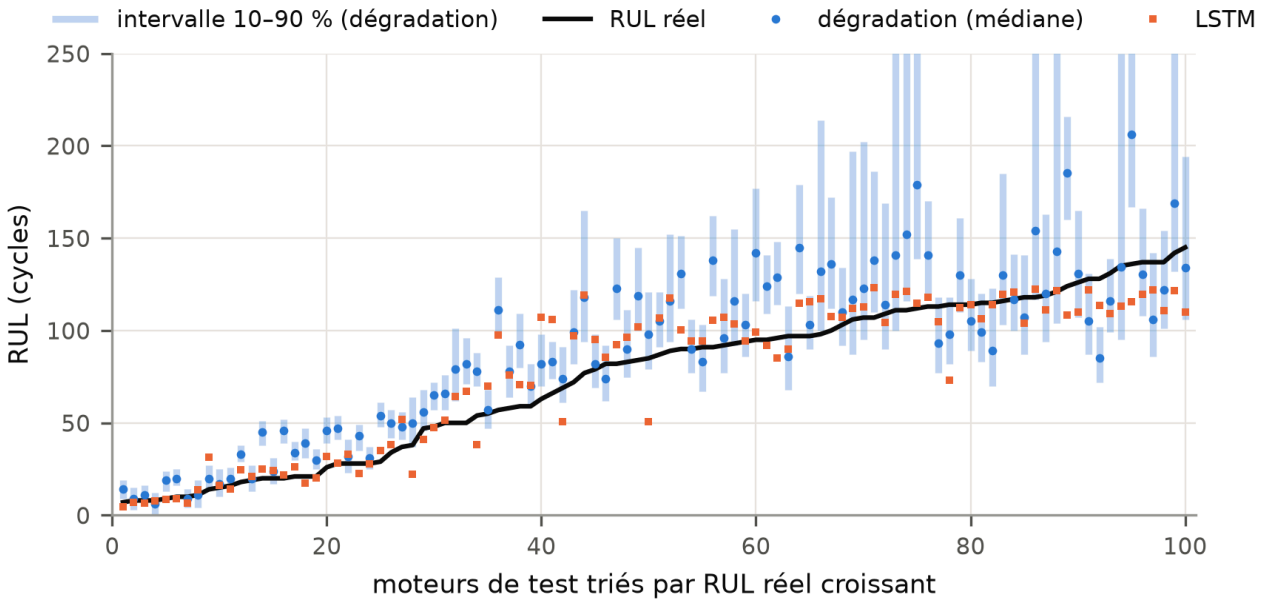


Figure 22 – Prédictions des deux modèles pour les moteurs de test triés par RUL réel, avec l'intervalle P10–P90 du modèle de dégradation.

7.4.2 Calibration du modèle de dégradation

Le tableau 9 et la figure 23 évaluent les intervalles de prédiction. À tous les niveaux, la couverture observée est inférieure au niveau nominal : 35 % pour l'intervalle P25–P75, 54 % pour P10–P90 et 59 % pour P05–P95. **Les intervalles sont trop étroits**, c'est-à-dire que le modèle sous-estime son incertitude.

Tableau 9 – Calibration des intervalles du modèle de dégradation

Intervalle	Niveau nominal	Couverture observée	Largeur moyenne
P25 – P75	50 %	35 %	21,7 cycles
P10 – P90	80 %	54 %	44,9 cycles
P05 – P95	90 %	59 %	65,0 cycles

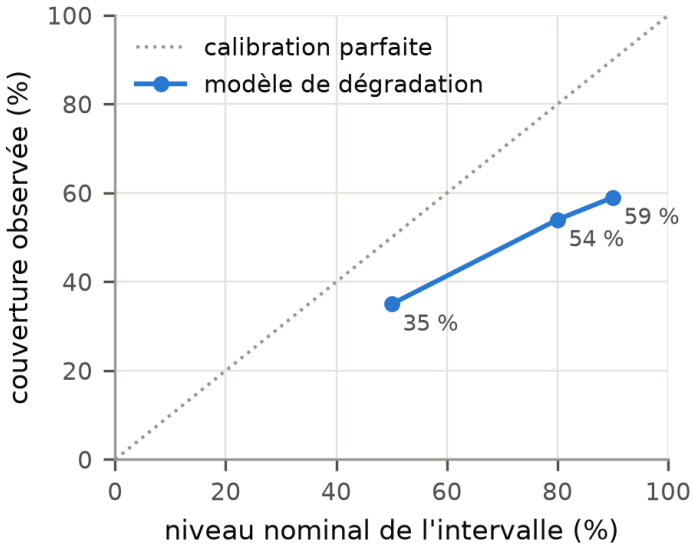


Figure 23 – Calibration des intervalles du modèle de dégradation : couverture observée en fonction du niveau nominal.

Le tableau 10 détaille le biais selon le RUL réel. Le biais est positif dans toutes les tranches, avec un maximum de +21,4 cycles dans la tranche intermédiaire. Pour les moteurs dont le RUL réel est le plus grand, le biais est plus faible (+7,4) et la couverture meilleure (79 %), car les intervalles y sont beaucoup plus larges. Le biais médian vaut +11,5 cycles. À titre de diagnostic seulement, l'écart-type des erreurs vaut 20,4 cycles : c'est l'erreur qui resterait si le biais moyen était retiré. Ce n'est pas une performance atteignable, car le biais est mesuré sur le jeu de test lui-même.

Tableau 10 – Biais du modèle de dégradation selon le RUL réel

RUL réel	Moteurs	Biais moyen	MAE	Couverture 10–90 %
0 – 50 cycles	33	+11,5	11,7	42 %
50 – 100 cycles	34	+21,4	23,0	41 %
> 100 cycles	33	+7,4	22,2	79 %

7.4.3 Apprentissage du LSTM et exemple d'un moteur

L'apprentissage du LSTM (figure 24) s'arrête au bout de 59 époques ; l'arrêt précoce conserve les poids de la meilleure époque (RMSE de validation 13,41 cycles, sur la cible plafonnée). Les erreurs d'entraînement et de validation restent proches, sans signe de sur-apprentissage marqué.

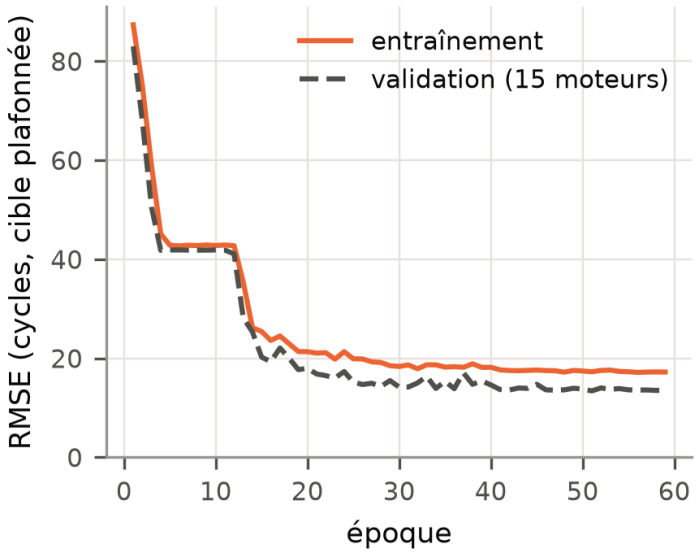


Figure 24 – Courbes d'apprentissage du LSTM : RMSE d'entraînement et de validation par époque.

La figure 25 illustre le fonctionnement des deux modèles sur le moteur de test n° 31, observé pendant 196 cycles et dont le RUL réel au dernier cycle est de 8 cycles. Au fil des cycles, les deux prédictions se rapprochent du RUL réel. Au dernier cycle, le modèle de dégradation prédit 9 cycles (intervalle P10–P90 de 3 à 15) et le LSTM 7 cycles. La projection de l'indicateur de santé montre comment le modèle bayésien déduit le RUL du franchissement du seuil.

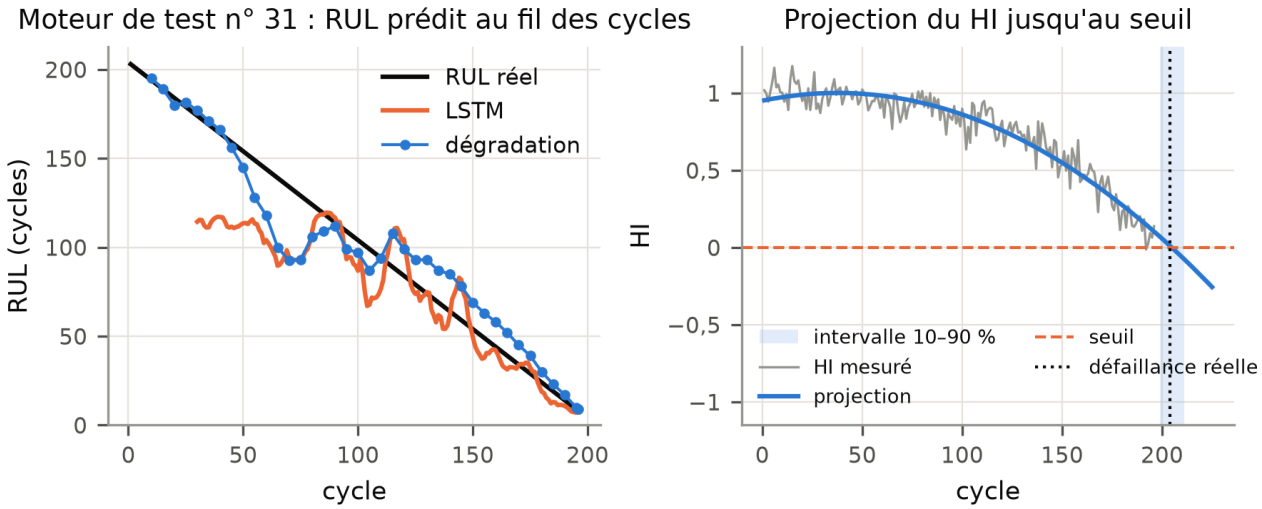


Figure 25 – Moteur de test pris en exemple : RUL prédit à chaque cycle par les deux modèles (gauche) et projection de l'indicateur de santé jusqu'au seuil de défaillance (droite).

7.5 Comparaison des méthodes

Les deux approches de RUL sont complémentaires :

- le **LSTM** est nettement plus précis et quasiment sans biais, ce qui est du même ordre que les réseaux récurrents publiés sur FD001 [23, 26]. En revanche, il ne fournit pas d'incertitude, ne peut pas dépasser son plafond et reste peu interprétable ;
- le **modèle de dégradation** est moins précis et biaisé vers les prédictions tardives, mais chacune de ses étapes est interprétable (trajectoire de l'indicateur de santé, seuil, loi a priori de flotte), et il fournit une distribution du RUL, même mal calibrée à ce stade.

Du côté de la fiabilité, l'approche non paramétrique (Kaplan-Meier, Nelson-Aalen) et l'approche paramétrique (Weibull 3P) concordent sur la forme du taux de défaillance et sur la médiane, ce qui renforce la confiance dans le modèle retenu.

8 Discussion

8.1 Interprétation industrielle

Une flotte qui s'use. Le paramètre de forme supérieur à un et le taux de défaillance croissant indiquent que les défaillances de FD001 sont des défaillances d'**usure**, ce qui est conforme au mécanisme simulé (dégradation progressive du compresseur haute pression). Dans ce cas, la maintenance préventive a un sens : remplacer un moteur âgé réduit réellement le risque, ce qui ne serait pas vrai avec un taux constant.

Une période sans défaillance. Le paramètre de position γ correspond à une durée pendant laquelle aucun moteur ne défaille. En exploitation, cette période peut servir à espacer les inspections lourdes en début de vie et à concentrer l'effort de surveillance au-delà de cet âge.

L'intérêt et la limite du préventif à âge fixe. La politique optimale remplace chaque moteur peu après la fin de la période sans défaillance, ce qui divise le coût par cycle d'un facteur important selon l'hypothèse de coûts retenue. Mais elle traite tous les moteurs de la même façon : elle remplace aussi les moteurs les plus robustes, et sacrifie en moyenne 75,6 cycles de vie utile par moteur.

L'apport du prédictif. C'est précisément ce que la maintenance prédictive peut améliorer : l'indicateur de santé, la détection de l'état critique et l'estimation du RUL permettent de décider moteur par moteur, de remplacer tôt les moteurs dégradés et d'exploiter plus longtemps les autres. Le LSTM fournit la prédiction la plus précise ; le modèle de dégradation fournit une explication et une incertitude, à condition d'en corriger la calibration. Dans une chaîne de décision, le classifieur peut jouer le rôle d'alarme et le modèle de RUL celui de planification.

8.2 Limites actuelles

Les limites suivantes sont connues et assumées dans cette Version 1 :

1. **Temps de réparation simulés.** Les résultats de maintenabilité, de disponibilité et de coût reposent sur une loi de réparation, une conversion cycle–heure et un rapport de coûts **supposés**. Ils illustrent la démarche du cours mais ne doivent pas être lus comme des valeurs industrielles.
2. **Un seul sous-ensemble, FD001.** Une seule condition opératoire et un seul mode de défaillance : les conclusions ne s'étendent pas telles quelles aux sous-ensembles plus complexes (FD002 à FD004), où les conditions de vol modifient fortement les capteurs.
3. **Loi retenue ajustée sur les seules défaillances.** La comparaison des lois et l'ajustement de la Weibull 3P utilisent les 100 durées de défaillance, sans les moteurs censurés. Kaplan-Meier, qui les inclut, donne une aire sous la courbe (214,3 cycles) supérieure au MTTF du modèle (206,3 cycles) : le modèle retenu sous-estime probablement un peu les durées de vie. Une estimation de la Weibull 3P par maximum de vraisemblance avec censure lèverait cette limite.
4. **Modèle markovien de disponibilité.** Il suppose des taux constants, alors que la loi retenue a un taux croissant : la courbe $A(t)$ est une approximation, seule sa limite est exacte.
5. **Biais et sous-couverture du modèle de dégradation.** Le modèle prédit en moyenne trop tard (+13,5 cycles) et ses intervalles sont trop étroits (54 % de couverture pour l'intervalle P10–P90). Plusieurs causes sont identifiées : (a) la base polynomiale de degré 2 extrapole mal une dégradation qui s'accélère en fin de vie ; (b) le bruit de mesure n'est pas propagé dans les trajectoires simulées, seule l'incertitude des coefficients et du seuil l'est ; (c) le seuil est estimé sur les valeurs ajustées et non sur les mesures. Une prédiction tardive est la plus dangereuse en maintenance : ce modèle ne doit pas être utilisé seul pour décider.

6. **Seuil de décision du classifieur.** Le rappel de test est faible au seuil par défaut, sur un jeu très déséquilibré. Le seuil devrait être choisi selon le coût relatif d'une défaillance manquée et d'une fausse alerte.
7. **Plafond et reproductibilité du LSTM.** Le LSTM ne peut pas prédire au-delà de son plafond, et son réentraînement varie légèrement selon la machine ; les résultats publiés correspondent au modèle sauvegardé.
8. **Évaluation sur un seul instant par moteur.** Le RUL n'est évalué qu'au dernier cycle observé de chaque moteur de test, comme dans le challenge PHM ; la qualité des prédictions au fil de la vie n'est illustrée que sur un exemple.

9 Perspectives

Ce chapitre présente les développements envisagés pour les Versions 2 et 3. **Aucun d'entre eux n'est réalisé à ce stade.** Pour chacun, les huit points suivants sont précisés : le développement envisagé, sa motivation, la limite actuelle qui le justifie, les données et ressources nécessaires, les méthodes envisageables, les expérimentations de validation, les bénéfices attendus et les difficultés prévisibles.

9.1 Modèles de dégradation probabilistes plus avancés

- **Développement :** remplacer la base polynomiale par un modèle exponentiel à coefficients aléatoires, puis par un processus de Wiener à dérive non linéaire [19, 20].
- **Motivation :** ces modèles décrivent mieux une dégradation qui s'accélère en fin de vie et intègrent naturellement le bruit de dégradation.
- **Limite actuelle :** le polynôme de degré 2 extrapole mal la fin de vie, ce qui contribue au biais de +13,5 cycles.
- **Données et ressources :** les mêmes données FD001 suffisent ; aucune ressource matérielle particulière.
- **Méthodes :** régression bayésienne sur le logarithme de l'indicateur, estimation par maximum de vraisemblance des paramètres du processus de Wiener, loi du premier temps de passage.
- **Validation :** comparaison du RMSE, du biais et du score NASA avec le modèle actuel, sur les mêmes moteurs de test.
- **Bénéfices attendus :** une réduction du biais et un modèle plus fidèle à la physique de l'usure.
- **Difficultés :** l'indicateur de santé peut devenir négatif, ce qui complique le passage au logarithme ; un recalage de l'indicateur sera nécessaire.

9.2 Amélioration de l'estimation du RUL et de la quantification des incertitudes

- **Développement :** propager le bruit de mesure dans les trajectoires simulées et recalibrer les intervalles de prédiction.
- **Motivation :** un intervalle n'est utile pour planifier la maintenance que s'il couvre réellement le RUL dans la proportion annoncée.
- **Limite actuelle :** l'intervalle P10–P90 ne couvre le RUL réel que dans 54 % des cas.
- **Données et ressources :** les moteurs d'entraînement, dont une partie serait réservée à la calibration.
- **Méthodes :** simulation du bruit dans les trajectoires, recalibration par quantiles sur un jeu de validation, prédiction conforme.
- **Validation :** courbes de calibration à plusieurs niveaux, sur des moteurs jamais utilisés pour l'apprentissage ni pour la calibration.
- **Bénéfices attendus :** des intervalles fiables, utilisables pour un remplacement fondé sur un niveau de risque maîtrisé.
- **Difficultés :** des intervalles mieux calibrés seront aussi plus larges ; il faudra trouver un compromis entre couverture et utilité.

9.3 Étude approfondie des indicateurs B10 et B50

- **Développement :** calculer des intervalles de confiance des durées B_{10} et B_{50} et étudier leur sensibilité au choix de la loi.
- **Motivation :** ces durées servent à fixer des intervalles de maintenance ; leur incertitude doit être connue.
- **Limite actuelle :** les durées B_p sont données sans intervalle de confiance, et deux lois équivalentes (Weibull 3P et log-normale) peuvent en donner des valeurs différentes.
- **Données et ressources :** les 200 durées de vie, censures comprises.
- **Méthodes :** bootstrap non paramétrique [36], méthode delta, ajustement de la Weibull 3P avec censure.
- **Validation :** stabilité des intervalles selon le nombre de rééchantillonnages ; comparaison des valeurs selon la loi retenue.
- **Bénéfices attendus :** des recommandations de maintenance accompagnées de leur incertitude.
- **Difficultés :** l'estimation du paramètre de position par maximum de vraisemblance est délicate, en particulier sur des échantillons rééchantillonnés.

9.4 Intégration de covariables externes

- **Développement :** tenir compte des conditions de vol dans la fiabilité et dans le pronostic.
- **Motivation :** en exploitation réelle, la durée de vie dépend fortement des conditions d'utilisation.
- **Limite actuelle :** FD001 ne comporte qu'une seule condition opératoire ; cette perspective nécessite les sous-ensembles **FD002 et FD004**, qui en comportent six.
- **Données et ressources :** les sous-ensembles FD002 et FD004, plus volumineux, et un temps de calcul accru.
- **Méthodes :** modèle à risques proportionnels de Cox [37], normalisation des capteurs par condition opératoire.
- **Validation :** comparaison des performances avec et sans covariables, sur les jeux de test officiels.
- **Bénéfices attendus :** des modèles transposables à des conditions d'exploitation variées.
- **Difficultés :** la normalisation par condition opératoire et la présence de deux modes de défaillance dans FD004.

9.5 Explicabilité des modèles d'apprentissage

- **Développement :** expliquer les prédictions du classifieur et du LSTM.
- **Motivation :** une décision de maintenance doit pouvoir être justifiée auprès des équipes techniques et des autorités.
- **Limite actuelle :** le LSTM et le gradient boosting sont des modèles opaques ; seuls les poids de l'indicateur de santé sont interprétables.
- **Données et ressources :** les modèles existants et les données de test.
- **Méthodes :** valeurs de Shapley, méthode SHAP [38], et attributions temporelles pour le LSTM.
- **Validation :** cohérence des capteurs les plus influents avec la physique de la dégradation du compresseur haute pression.
- **Bénéfices attendus :** une confiance accrue des utilisateurs et une vérification de l'absence de corrélations parasites.

- **Difficultés :** le coût de calcul des explications sur des séquences et l'interprétation d'attributions corrélées entre capteurs.

9.6 Stratégies de pondération

- **Développement :** améliorer la fusion des capteurs dans l'indicateur de santé et la pondération des deux modèles de RUL.
- **Motivation :** une moyenne simple des deux modèles n'améliore pas le LSTM seul.
- **Limite actuelle :** l'indicateur de santé est une régression linéaire simple, et la combinaison des modèles est une moyenne non pondérée (RMSE 16,91 contre 15,35 pour le LSTM seul).
- **Données et ressources :** les moteurs d'entraînement, avec un jeu de validation dédié à l'apprentissage des poids.
- **Méthodes :** sélection par monotonie et pronosticabilité [17], pondération selon l'incertitude, empilement de modèles.
- **Validation :** validation croisée par groupes de moteurs, comme pour la classification.
- **Bénéfices attendus :** un indicateur plus monotone et une combinaison au moins aussi précise que le meilleur modèle.
- **Difficultés :** le risque de sur-apprentissage des poids sur un nombre limité de moteurs.

9.7 Analyses de sensibilité et de robustesse

- **Développement :** mesurer l'effet des choix de paramètres sur les résultats.
- **Motivation :** plusieurs paramètres sont fixés par convention et non optimisés.
- **Limite actuelle :** le seuil de criticité (30 cycles), la taille des fenêtres, le plafond du LSTM et les hypothèses de réparation et de coût sont fixés sans étude de sensibilité.
- **Données et ressources :** les données actuelles ; un temps de calcul proportionnel au nombre de configurations testées.
- **Méthodes :** plans d'expériences, variation d'un facteur à la fois, analyse de sensibilité globale.
- **Validation :** stabilité des conclusions (choix de la loi, âge optimal, classement des modèles) selon les paramètres.
- **Bénéfices attendus :** des conclusions dont la robustesse est démontrée.
- **Difficultés :** le nombre de combinaisons croît vite, en particulier si le LSTM doit être réentraîné.

9.8 Benchmarks élargis, apprentissage profond et Transformers

- **Développement :** comparer davantage de familles de modèles : réseaux convolutifs, GRU, Transformers et forêts de survie aléatoires.
- **Motivation :** situer les deux modèles actuels par rapport à l'état de l'art [24, 25, 26].
- **Limite actuelle :** seules deux approches sont comparées.
- **Données et ressources :** les quatre sous-ensembles C-MAPSS, et éventuellement un processeur graphique.
- **Méthodes :** réseaux convolutifs temporels, GRU, Transformers [39], forêts de survie aléatoires [40], avec un protocole d'évaluation commun.
- **Validation :** mêmes métriques, mêmes moteurs de test et plusieurs graines pour les modèles stochastiques.
- **Bénéfices attendus :** un choix de modèle argumenté par une comparaison équitable.

- **Difficultés :** le coût de calcul, et le risque d'optimiser les modèles sur le jeu de test ; les Transformers ne seront retenus que si leur gain le justifie au regard de leur complexité.

9.9 Passage à des données industrielles réelles

- **Développement :** appliquer la chaîne à des données de capteurs réelles.
- **Motivation :** C-MAPSS est une simulation ; les données réelles sont plus bruitées, incomplètes et comportent des maintenances intermédiaires.
- **Limite actuelle :** toutes les données utilisées sont simulées, et les temps de réparation le sont aussi.
- **Données et ressources :** un partenariat industriel, des historiques de capteurs et de maintenance, et un cadre de confidentialité.
- **Méthodes :** nettoyage et synchronisation des données, traitement des valeurs manquantes, prise en compte des maintenances imparfaites.
- **Validation :** comparaison des prédictions avec les défaillances et les déposes réellement constatées.
- **Bénéfices attendus :** une validation de l'approche dans un contexte réel.
- **Difficultés :** l'accès aux données, leur qualité et le faible nombre de défaillances observées.

9.10 Modèles hybrides et apprentissage informé par la physique

- **Développement :** combiner un modèle physique de la dégradation et un modèle appris.
- **Motivation :** les modèles purement statistiques n'intègrent pas les lois physiques connues du moteur.
- **Limite actuelle :** les modèles actuels sont entièrement guidés par les données.
- **Données et ressources :** une connaissance des lois de dégradation du compresseur et, idéalement, un modèle thermodynamique simplifié du moteur.
- **Méthodes :** réseaux informés par la physique [41], modèles hybrides où le réseau corrige un modèle physique.
- **Validation :** précision, mais aussi cohérence physique des prédictions, par exemple la monotonie de la dégradation.
- **Bénéfices attendus :** une meilleure extrapolation avec peu de données et des prédictions physiquement plausibles.
- **Difficultés :** la formulation des contraintes physiques et l'équilibre entre les termes de la fonction de coût.

9.11 Optimisation avancée de la planification de la maintenance

- **Développement :** passer de la politique d'âge fixe à une planification dynamique fondée sur le RUL prédit.
- **Motivation :** la politique actuelle sacrifie en moyenne 75,6 cycles de vie utile par moteur.
- **Limite actuelle :** la politique optimisée est identique pour tous les moteurs et ignore leur état.
- **Données et ressources :** les distributions du RUL, des contraintes opérationnelles (disponibilité des équipes, des pièces et des créneaux).
- **Méthodes :** politiques de remplacement conditionnelles au risque, programmation linéaire en nombres entiers, optimisation sous incertitude.
- **Validation :** simulation de la flotte sur un horizon long, comparaison des coûts et du nombre de défaillances en service.
- **Bénéfices attendus :** une réduction du coût et de la vie sacrifiée par rapport à la politique d'âge fixe.

- **Difficultés :** la nécessité d'intervalles de RUL bien calibrés, d'où le lien avec la section 9.2.

9.12 Jumeau numérique

- **Développement :** intégrer les modèles dans un jumeau numérique de la flotte, mis à jour en continu.
- **Motivation :** suivre l'état de chaque moteur en temps réel et simuler des scénarios de maintenance [42].
- **Limite actuelle :** les modèles sont appliqués hors ligne, sur des fichiers.
- **Données et ressources :** un flux de données en continu et une infrastructure logicielle de déploiement.
- **Méthodes :** mise à jour bayésienne en ligne (déjà compatible avec le modèle de dégradation), architecture orientée événements.
- **Validation :** latence de mise à jour et stabilité des prédictions dans le temps.
- **Bénéfices attendus :** une aide à la décision en temps réel.
- **Difficultés :** l'intégration aux systèmes existants et la maintenance du logiciel.

9.13 Étude économique industrielle complète

- **Développement :** remplacer les coûts relatifs supposés par des coûts réels.
- **Motivation :** l'âge optimal et le gain dépendent directement du rapport des coûts.
- **Limite actuelle :** le rapport C_c/C_p est une hypothèse d'illustration, et l'immobilisation n'est pas chiffrée.
- **Données et ressources :** des coûts de pièces, de main-d'œuvre et d'immobilisation, auprès d'un exploitant.
- **Méthodes :** modèle de coût complet incluant l'immobilisation, les stocks et les pénalités, analyse de sensibilité aux coûts.
- **Validation :** comparaison avec les coûts historiques d'un exploitant.
- **Bénéfices attendus :** une recommandation économiquement justifiée.
- **Difficultés :** la confidentialité et la variabilité des coûts.

9.14 Déploiement et validation en environnement industriel

- **Développement :** déployer le tableau de bord et l'API auprès d'utilisateurs réels.
- **Motivation :** vérifier l'utilité de l'outil dans le processus de décision.
- **Limite actuelle :** l'application fonctionne en local, avec des données figées.
- **Données et ressources :** un serveur, une authentification des utilisateurs et une connexion aux données réelles.
- **Méthodes :** conteneurisation, intégration continue s'appuyant sur la suite de tests existante, surveillance de la dérive des données.
- **Validation :** retours des utilisateurs et indicateurs de maintenance avant et après le déploiement.
- **Bénéfices attendus :** un outil réellement utilisé pour la maintenance.
- **Difficultés :** la sécurité, la fiabilité du service et la conduite du changement.

10 Conclusion

Cette première version de l'étude a appliqué l'ensemble de la démarche de sûreté de fonctionnement à une flotte de turboréacteurs simulés, des données brutes jusqu'à un outil d'aide à la décision.

L'analyse de fiabilité, menée en tenant compte des 100 moteurs censurés, montre une flotte soumise à l'usure, avec une période sans défaillance. La loi de Weibull à trois paramètres, validée par le test de Kolmogorov-Smirnov et équivalente à la loi log-normale selon l'AIC, donne un MTTF de 206,3 cycles et des durées B_{10} et B_{50} de 151,9 et 199,9 cycles. Sous des hypothèses de réparation et de coût explicitement signalées, la disponibilité intrinsèque atteint 95,98 % et un remplacement préventif à 131 cycles réduit le coût par cycle de 68 %.

La chaîne de maintenance prédictive complète cette vision globale par une décision moteur par moteur. Un indicateur de santé construit sur 12 capteurs décrit la dégradation de façon monotone, le classifieur détecte l'état critique avec une AUC de 0,991, et deux modèles estiment la durée de vie résiduelle. Le LSTM est le plus précis (RMSE de 15,35 cycles). Le modèle de dégradation bayésien, moins précis (RMSE de 24,47 cycles), est interprétable et probabiliste ; son biais et la calibration insuffisante de ses intervalles sont identifiés, mesurés et expliqués.

Enfin, l'ensemble est livré sous la forme d'un système reproductible : pipeline, API, tableau de bord et suite de tests automatiques, qui garantit que chaque chiffre de ce rapport provient du code. Les perspectives prioritaires pour la Version 2 sont l'amélioration du modèle de dégradation et de ses intervalles, l'estimation de la loi à trois paramètres avec censure, et l'extension aux sous-ensembles comportant plusieurs conditions opératoires.

Bibliographie

1. A. Saxena, K. Goebel, *Turbofan Engine Degradation Simulation Data Set*, NASA Ames Prognostics Data Repository, NASA Ames Research Center, Moffett Field, CA, 2008.
2. A. Saxena, K. Goebel, D. Simon, N. Eklund, « Damage propagation modeling for aircraft engine run-to-failure simulation », *International Conference on Prognostics and Health Management (PHM 2008)*, IEEE, 2008.
3. AFNOR, *NF EN 13306 : Maintenance — Terminologie de la maintenance*, 2018.
4. A. K. S. Jardine, D. Lin, D. Banjevic, « A review on machinery diagnostics and prognostics implementing condition-based maintenance », *Mechanical Systems and Signal Processing*, vol. 20, n° 7, p. 1483–1510, 2006.
5. F. Ben Hmida, *Estimation des indices FMDS*, support de cours du module « Sûreté de fonctionnement et maintenance », GMAM 3, ENSIT, 2025.
6. Y. Lei, N. Li, L. Guo, N. Li, T. Yan, J. Lin, « Machinery health prognostics: A systematic review from data acquisition to RUL prediction », *Mechanical Systems and Signal Processing*, vol. 104, p. 799–834, 2018.
7. X.-S. Si, W. Wang, C.-H. Hu, D.-H. Zhou, « Remaining useful life estimation — A review on the statistical data driven approaches », *European Journal of Operational Research*, vol. 213, n° 1, p. 1–14, 2011.
8. E. L. Kaplan, P. Meier, « Nonparametric estimation from incomplete observations », *Journal of the American Statistical Association*, vol. 53, n° 282, p. 457–481, 1958.
9. M. Greenwood, « The natural duration of cancer », *Reports on Public Health and Medical Subjects*, n° 33, His Majesty's Stationery Office, Londres, 1926.
10. W. Nelson, « Theory and applications of hazard plotting for censored failure data », *Technometrics*, vol. 14, n° 4, p. 945–966, 1972.
11. O. Aalen, « Nonparametric inference for a family of counting processes », *The Annals of Statistics*, vol. 6, n° 4, p. 701–726, 1978.
12. W. Weibull, « A statistical distribution function of wide applicability », *Journal of Applied Mechanics*, vol. 18, p. 293–297, 1951.
13. A. Bernard, E. C. Bos-Levenbach, « The plotting of observations on probability paper », *Statistica Neerlandica*, vol. 7, p. 163–173, 1953.
14. F. J. Massey, « The Kolmogorov-Smirnov test for goodness of fit », *Journal of the American Statistical Association*, vol. 46, n° 253, p. 68–78, 1951.
15. H. Akaike, « A new look at the statistical model identification », *IEEE Transactions on Automatic Control*, vol. 19, n° 6, p. 716–723, 1974.
16. R. E. Barlow, F. Proschan, *Mathematical Theory of Reliability*, John Wiley & Sons, New York, 1965.
17. J. Coble, J. W. Hines, « Identifying optimal prognostic parameters from data: a genetic algorithms approach », *Annual Conference of the Prognostics and Health Management Society*, 2009.
18. T. Wang, J. Yu, D. Siegel, J. Lee, « A similarity-based prognostics approach for remaining useful life estimation of engineered systems », *International Conference on Prognostics and Health Management (PHM 2008)*, IEEE, 2008.
19. N. Z. Gebraeel, M. A. Lawley, R. Li, J. K. Ryan, « Residual-life distributions from component degradation signals: A Bayesian approach », *IIE Transactions*, vol. 37, n° 6, p. 543–557, 2005.
20. X.-S. Si, W. Wang, C.-H. Hu, D.-H. Zhou, M. G. Pecht, « Remaining useful life estimation based on a nonlinear diffusion degradation process », *IEEE Transactions on Reliability*, vol. 61, n° 1, p. 50–67, 2012.
21. F. O. Heimes, « Recurrent neural networks for remaining useful life estimation », *International Conference on Prognostics and Health Management (PHM 2008)*, IEEE, 2008.
22. S. Hochreiter, J. Schmidhuber, « Long short-term memory », *Neural Computation*, vol. 9, n° 8, p. 1735–1780, 1997.

23. S. Zheng, K. Ristovski, A. Farahat, C. Gupta, « Long short-term memory network for remaining useful life estimation », *IEEE International Conference on Prognostics and Health Management (ICPHM)*, 2017.

24. G. S. Babu, P. Zhao, X.-L. Li, « Deep convolutional neural network based regression approach for estimation of remaining useful life », *Database Systems for Advanced Applications (DASFAA 2016)*, Lecture Notes in Computer Science, vol. 9642, Springer, 2016.

25. X. Li, Q. Ding, J.-Q. Sun, « Remaining useful life estimation in prognostics using deep convolution neural networks », *Reliability Engineering & System Safety*, vol. 172, p. 1–11, 2018.

26. E. Ramasso, A. Saxena, « Performance benchmarking and analysis of prognostic methods for CMAPSS datasets », *International Journal of Prognostics and Health Management*, vol. 5, n° 2, 2014.

27. C. Davidson-Pilon, « lifelines: survival analysis in Python », *Journal of Open Source Software*, vol. 4, n° 40, p. 1317, 2019.

28. F. Pedregosa *et al.*, « Scikit-learn: Machine learning in Python », *Journal of Machine Learning Research*, vol. 12, p. 2825–2830, 2011.

29. J. H. Friedman, « Greedy function approximation: A gradient boosting machine », *The Annals of Statistics*, vol. 29, n° 5, p. 1189–1232, 2001.

30. G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, T.-Y. Liu, « LightGBM: A highly efficient gradient boosting decision tree », *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017.

31. C. Cortes, V. Vapnik, « Support-vector networks », *Machine Learning*, vol. 20, p. 273–297, 1995.

32. J. Platt, « Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods », dans *Advances in Large Margin Classifiers*, MIT Press, 1999.

33. D. P. Kingma, J. Ba, « Adam: A method for stochastic optimization », *International Conference on Learning Representations (ICLR)*, 2015.

34. A. Paszke *et al.*, « PyTorch: An imperative style, high-performance deep learning library », *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*, 2019.

35. J. A. Hanley, B. J. McNeil, « The meaning and use of the area under a receiver operating characteristic (ROC) curve », *Radiology*, vol. 143, n° 1, p. 29–36, 1982.

36. B. Efron, « Bootstrap methods: Another look at the jackknife », *The Annals of Statistics*, vol. 7, n° 1, p. 1–26, 1979.

37. D. R. Cox, « Regression models and life-tables », *Journal of the Royal Statistical Society, Series B*, vol. 34, n° 2, p. 187–220, 1972.

38. S. M. Lundberg, S.-I. Lee, « A unified approach to interpreting model predictions », *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017.

39. A. Vaswani *et al.*, « Attention is all you need », *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017.

40. H. Ishwaran, U. B. Kogalur, E. H. Blackstone, M. S. Lauer, « Random survival forests », *The Annals of Applied Statistics*, vol. 2, n° 3, p. 841–860, 2008.

41. M. Raissi, P. Perdikaris, G. E. Karniadakis, « Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations », *Journal of Computational Physics*, vol. 378, p. 686–707, 2019.

42. F. Tao, H. Zhang, A. Liu, A. Y. C. Nee, « Digital twin in industry: State-of-the-art », *IEEE Transactions on Industrial Informatics*, vol. 15, n° 4, p. 2405–2415, 2019.

Annexes

Annexe A — Hypothèses et paramètres

Tableau 11 – Hypothèses et paramètres des méthodes

Paramètre	Valeur	Module
Conversion temps	1 cycle ≈ 2 h (1 vol)	fmds.py
Temps de réparation simulés	log-normale, médiane 16 h, σ = 0,6, graine 42	fmds.py
Coûts relatifs	Cp = 1, Cc = 5	fmds.py
Capteur constant	moins de 10 valeurs distinctes	features.py
Sélection des capteurs	|tendance| ≥ 0,5	features.py
Fenêtre glissante (features, lissage du HI)	10 cycles	features.py
Cible du HI	1 sur les 10 % premiers cycles, 0 sur les 10 % derniers	features.py
Classe « critique »	RUL ≤ 30 cycles ; « surveillance » si P ≥ 0,2	health.py
Modèle de dégradation	polynôme de degré 2, 1000 tirages, horizon 400 cycles	rul_degradation.py
LSTM	fenêtres de 30 cycles, cible plafonnée à 125, 2 couches de 64	rul_lstm.py

Annexe B — Structure du dépôt

```
data/raw/                     jeu C-MAPSS FD001 (train, test, RUL)
backend/
  pipeline/data.py            SET-02   chargement, RUL, table de durées de vie, description
  pipeline/fmds.py            FMDS-01  fiabilité ; FMDS-02 maintenabilité, disponibilité, pré-
ventif
  pipeline/features.py        PDM-01   capteurs, features, indicateur de santé
  pipeline/health.py          PDM-02   classification normal / critique
  pipeline/rul_degradation.py RUL-01   modèle de dégradation bayésien
  pipeline/rul_lstm.py        RUL-02   LSTM
  run_all.py                  RUL-03   orchestration et export des résultats
  report_figures.py           figures du rapport
  report_tables.py            tableaux et valeurs du rapport
  api/main.py                 WEB-01   API FastAPI
  models/  results/           modèles sauvegardés et résultats JSON
frontend/                     WEB-02   tableau de bord React (src/, dist/)
dashboard_autonome.html       tableau de bord autonome (un seul fichier)
report/                       rapport : source/, figures/, tables/, build.mjs
tests/                        suite de tests pytest ; frontend/tests : Playwright
```

Annexe C — Guide de lancement

```
# tableau de bord (résultats déjà calculés)
cd backend
pip install -r requirements.txt
python -m uvicorn api.main:app --port 8000        # http://localhost:8000

# recalcul complet, figures, tableaux
python run_all.py
python report_figures.py
python report_tables.py

# rapport (Node.js)
cd ../report
npm install
node build.mjs                                     # -> Rapport_V1_FMDS_Eya_Salma.pdf

# tests
cd ..
run_tests.bat --slow
```

La version autonome `dashboard_autonome.html` s'ouvre directement dans un navigateur, sans installation.

Annexe D — Répartition du travail

Ticket	Contenu	Responsable
SET-02	Chargement des données, RUL, table de durées de vie, description du jeu	Salma
FMDS-01	Fiabilité : Kaplan-Meier, Nelson-Aalen, Weibull, adéquation, indicateurs	Eya
FMDS-02	Maintenabilité, disponibilité, remplacement préventif	Salma
PDM-01	Sélection des capteurs, features, indicateur de santé	Salma
PDM-02	Classification normal / critique	Eya
RUL-01	Modèle de dégradation bayésien	Eya
RUL-02	Réseau LSTM	Salma
RUL-03	Orchestration, comparaison, export	Eya et Salma
WEB-01	API FastAPI	Eya
WEB-02	Tableau de bord React	Salma
Rapport	Figures, tableaux, rédaction	Eya et Salma